

分类号： TP391

单位代码： 10431

密 级：

学 号： 10431220641

齊魯工業大學

硕士学位论文

(专业学位)

面向数字病理图像的细胞核分割方法研究

作 者 姓 名 _____ 鲁从健

领 域 _____ 计算机技术

所 在 学 部 _____ 数学与人工智能学部

指导教师姓名 _____ 周书旺

专业技术职务 _____ 副研究员

2025 年 6 月 6 日

**A Thesis Submitted for the Application of
the Master's Degree of Engineering**

**Research on Nuclei Segmentation Methods
for Digital Pathological Images**

Candidate: Lu Congjian

Specialty: Computer Technology

Supervisor: Associate Researcher Zhou Shuwang

**Qilu University of Technology, Jinan, China
June, 2025**

目 录

第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 传统分割方法.....	2
1.2.2 基于深度学习的分割方法.....	3
1.3 本文主要研究内容.....	5
1.4 论文的组织结构.....	6
第 2 章 相关知识介绍	7
2.1 数字病理图像相关知识介绍	7
2.2 基于深度学习的细胞核分割相关技术	9
2.2.1 卷积神经网络.....	10
2.2.2 U 型编码-解码网络	12
2.2.3 多任务学习.....	14
2.2.4 CLIP	16
2.3 细胞核分割数据集介绍.....	20
2.4 本章小结.....	21
第 3 章 基于点线面特征融合的细胞核实例分割算法	22
3.1 引言.....	22
3.2 基于点线面特征融合的分割模型	22
3.2.1 特征提取模块.....	23
3.2.2 关键点检测分支.....	24
3.2.3 区域优化模块.....	25
3.2.4 损失函数.....	26
3.2.5 后处理模块.....	27
3.3 实验结果与分析.....	27
3.3.1 实验设置.....	27
3.3.2 评价指标.....	28
3.3.3 对比实验.....	29
3.3.4 可视化分析.....	31
3.3.5 模型运行时间分析.....	32
3.3.6 消融实验.....	33
3.4 本章小结.....	34
第 4 章 基于密集连接网络与文本提示的细胞核分割算法	35
4.1 引言.....	35

4.2 基于密集连接网络与文本提示的分割模型	35
4.2.1 文本分支	36
4.2.2 图像分支	37
4.2.3 跨模态融合模块	38
4.2.4 跨模态注意力机制	39
4.2.5 损失函数	41
4.3 实验结果与分析	42
4.3.1 实验设置	42
4.3.2 对比实验	42
4.3.3 可视化分析	44
4.3.4 泛化性实验	45
4.3.5 消融实验	46
4.4 本章小结	48
第5章 总结与展望	49
5.1 结论	49
5.2 未来展望	50
参考文献	51

摘 要

疾病诊断在很大程度上依赖病理检验，而细胞核形态与结构的变化为疾病的检测提供了关键线索。在这一过程中，精确分割细胞核成为病理诊断的基础性任务。传统显微镜检查费时费力，且受主观影响较大，增加了诊断不确定性。全切片扫描仪推动了病理图像数字化，结合人工智能等技术，数字病理系统为临床提供了新的辅助诊断方式。尽管深度学习在细胞核分割任务中展现出显著潜力，但仍面临诸多挑战，如细胞核重叠、边界模糊及模型泛化能力不足等限制了实际应用。针对上述问题，本文的主要研究工作如下：

(1) 针对病理图像中细胞核相互重叠、边界模糊的问题，本文提出了一种新的基于点线面特征融合的细胞核实例分割算法（SES-Net），弥补了现有细胞核实例分割方法在点、线与面信息融合方面的不足。首先，设计了一个三支网络结构，其中包括用于精确定位细胞核的关键点分支，用于描述细胞核形状和轮廓的边缘分支，以及用于全面表征细胞核区域的掩码分支。接下来，提出了一个区域优化模块（ROM），该模块有效地集成了关键点和边缘特征，以区分重叠实例并细化分割掩码。最后，设计了一种将 ROM 输出与细胞核掩码图像相结合的后处理方法，以产生最终的实例分割结果。本文提出的方法在 MoNuSeg、CoNSeP 和 CMP-17 数据集上的 Dice 系数相较于现有主流方法分别提升了 4.0%、7.1% 和 2.3%。实验结果表明，该方法采用的三支网络结构在分离重叠细胞核任务中展现了显著的优势。

(2) 针对传统多路径结构在细胞核分割中导致的特征竞争和泛化能力不足的问题，本文提出了一种基于密集连接网络与文本提示的细胞核分割算法（CRU-Net）。首先，引入 CLIP 模型的语义信息，为每个细胞核图像提供文本描述（如细胞核、边界、背景），从而为模型注入细胞核语义先验信息。接下来，在 U-Net 架构基础上设计密集连接包括密集的下采样和上采样路径，并在编码器瓶颈处加入跨模态融合模块，以融合文本与图像特征。最后，提出一种基于跨模态注意力机制的跳跃连接，通过计算图像和文本特征之间的相似性，动态调整图像特征的注意力权重，增强高低层特征信息交互。本文提出的方法在 MoNuSeg 和 CoNSeP 数据集上的 Dice、AJI 和 PQ 指标均有所提升，其中跨数据集验证的最高提升分别达到 12%、4% 和 12.5%。实验结果表明，该方法借助文本提示增加了模型的先验知识，提升了分割准确率和泛化能力。

关键词：图像分割；深度学习；多路径模型；文本提示；细胞核分割

ABSTRACT

Disease diagnosis largely relies on pathological examinations, where changes in the morphology and structure of cell nuclei provide crucial clues for disease detection. In this process, accurate segmentation of nuclei becomes a fundamental task in pathological diagnosis. Traditional microscopic examinations are time-consuming and labor-intensive, and are heavily influenced by subjective factors, which increases diagnostic uncertainty. Whole-slide scanners have facilitated the digitization of pathological images, and combined with artificial intelligence and other technologies, digital pathology systems offer a new approach for clinical diagnostic assistance. Although deep learning has shown significant potential in nuclei segmentation tasks, it still faces several challenges, such as overlapping nuclei, blurred boundaries, and insufficient model generalization, which limit its practical application. To address these issues, the main contributions of this thesis are as follows:

(1) To address the challenges of overlapping nuclei and blurred boundaries in pathological images, this thesis proposes a novel instance segmentation algorithm for nuclei (SES-Net) based on the fusion of point, line, and surface features. This method compensates for the limitations of existing instance segmentation approaches in integrating point, edge, and region information. Specifically, a three-branch network architecture is designed, consisting of: a keypoint branch for precise nucleus localization, an edge branch for capturing nuclear shape and contour, and a mask branch for comprehensive region representation. Subsequently, a Region Optimization Module (ROM) is introduced to effectively integrate keypoint and edge features, enabling better discrimination of overlapping instances and refinement of the segmentation masks. Finally, a post-processing strategy is developed to fuse the ROM output with the nucleus mask image, generating the final instance segmentation results. The proposed method achieves improvements in Dice coefficient of 4.0%, 7.1%, and 2.3% on the MoNuSeg, CoNSeP, and CMP-17 datasets, respectively, compared with existing state-of-the-art methods. Experimental results demonstrate that the proposed three-branch architecture exhibits significant advantages in separating overlapping nuclei.

(2) To address the issues of feature competition and limited generalization ability caused by traditional multi-path structures in nuclear segmentation, this thesis proposes a novel segmentation algorithm (CRU-Net) based on dense connectivity and textual

prompts. First, semantic information from the CLIP model is introduced by providing textual descriptions (e.g., nuclei, boundary, background) for each nuclei image, thereby injecting semantic prior knowledge into the model. Then, building upon the U-Net architecture, densely connected downsampling and upsampling paths are designed, and a Cross-modal Fusion Module is incorporated at the encoder bottleneck to effectively fuse textual and visual features. Finally, a cross-modal attention-based skip connection mechanism is proposed, which dynamically adjusts the attention weights of image features by computing the similarity between image and text features, thus enhancing the interaction between low-level and high-level features. The proposed method achieves consistent improvements in Dice, AJI, and PQ metrics on both the MoNuSeg and CoNSeP datasets, with maximum cross-dataset gains reaching 12%, 4%, and 12.5%, respectively. Experimental results demonstrate that the incorporation of textual prompts effectively augments the model's prior knowledge, thereby improving segmentation accuracy and generalization performance.

Keywords: Image Segmentation, Deep Learning, Multipath Model, Text Prompt, Nuclei Segmentation

第 1 章 绪论

1.1 研究背景及意义

由于全球人口老龄化以及生活方式的变化，癌症的发病率和死亡率不断攀升。根据 2024 年世界卫生组织（WHO）的数据^[1]，癌症是全球第二大死亡原因，每年约有 1900 万人被诊断为癌症，1000 万人因癌症死亡。肺癌、结直肠癌和胃癌等均为最常见的癌症类型，尤其在一些发展中国家，由于环境污染和不良生活习惯，癌症的发病率呈现逐年上升的趋势^[2]。在此背景下，病理学作为连接基础医学与临床医学的关键学科，特别在癌症诊断、分期、分级、治疗决策和预后评估中至关重要。通过组织学检查，病理学为临床提供关键信息，帮助医生制定更精确的治疗方案和预测疾病进展。通过组织切片或细胞样本的显微镜检查，病理学帮助判断肿瘤的性质、类型和恶性程度，提供精确的诊断信息^[3]。此外，病理学还通过分子标记物和免疫组化染色技术，揭示癌细胞的分子特征，为靶向治疗和个体化治疗提供指导。癌症的分期和分级通过病理分析能够为治疗方案的选择提供依据，而免疫表型分析则帮助评估免疫疗法的疗效。随着精准医学和人工智能的进步，病理学在癌症早期检测、治疗监测和癌症研究中的作用愈发重要，推动着癌症治疗向更加精确、高效的方向发展^[4]。

随着数字病理学和计算机辅助诊断（Computer-Aided Diagnosis, CAD）的快速发展，传统的人工病理诊断逐渐向数字化、自动化方向转型。数字病理图像通过高分辨率扫描技术将组织切片转换为数字图像，病理学家可以在计算机上查看和分析这些图像。然而，由于病理图像中细胞和组织结构的复杂性，自动化细胞核分割成为病理图像分析中的关键任务之一^[5]。细胞核是细胞的核心部分，其形态、数量和排列方式对疾病的诊断具有重要意义。在肿瘤、感染及遗传性疾病等病症的研究中，细胞核的形态学特征被认为是判定病变的重要依据。传统的细胞核分割方法依赖于人工标注和经验，工作量大且易受到人为因素的影响，因此，研究并开发准确、高效的细胞核分割方法显得尤为重要。

目前，随着深度学习和人工智能技术在计算机视觉领域的广泛应用，基于深度学习的细胞核分割方法在医学图像处理中取得了显著进展^[6]。然而，由于病理图像在细胞核形态、大小、密度以及组织背景等方面的复杂性，现有分割方法仍面临诸多挑战。例如，细胞核之间可能存在重叠、形态变化，或者病理图像质量存在较大差异，使得模型在泛化能力和鲁棒性方面仍有提升空间。因此，如何进一步优化分割方法，以更精准地适应不同类型的病理图像，仍是未来值得深入研究的方向。

1.2 国内外研究现状

细胞核分割是数字病理图像分析中诊断与治疗的重要前置任务。由于疾病进展与组织特征密切相关,该任务通常依赖病理医生手工完成。然而,该过程不仅耗时繁琐,且劳动强度较大,给临床工作带来了沉重的负担。因此,亟需设计准确可靠的自动化分割方法,以提高临床诊断效率并减轻病理医生负担。尽管阈值分割、分水岭算法以及区域生长等传统方法在特定场景下仍具一定有效性,但随着医学图像任务的复杂性不断提升,深度学习技术已逐渐成为主流,并在细胞核分割领域取得了显著进展。第 1.2.1 节介绍传统分割方法,第 1.2.2 节介绍深度学习的分割方法。

1.2.1 传统分割方法

阈值处理是最早应用于图像分割的方法之一,传统方法依赖低级图像特征或简单阈值策略来分割细胞,但难以找到适用于所有病理图像的最佳阈值^[7]。该方法通过像素强度划分类别,但在复杂图像中,由于细胞与背景的对比度变化,常导致结果不稳定。Lu 等^[8]提出了一种混合形态重建模块,通过降低细胞核区域的强度变化并抑制噪声,同时结合局部最优阈值的自适应策略进行分割。Wienert 等^[9]通过将大津阈值与轮廓拟合相结合,成功实现了多种组织类型的细胞分割,并获得了显著的分割效果。Zhou 等^[10]提出了一种自适应局部阈值化方法,利用重叠子区域划分图像,并在每个子区域内应用自适应阈值,从而在细胞分割上优于传统的全局阈值方法。但是,阈值方法容易受到复杂背景干扰,影响分割的可靠性。

分水岭算法的引入为分割任务提供了新的视角和解决方案^[11],并在多个领域的研究中展现出强大的应用潜力。该算法的核心思想是将图像看作地形表面,通过定义的标记进行“洪水填充”,从而逐步扩展区域。分水岭算法可以被看作一种区域增长的分割方法,其标记的准确性直接决定了分割的效果。为了提升分水岭算法的表现,许多研究致力于改进标记的生成和分割的鲁棒性。例如,Zhou 等人^[12]通过自适应阈值生成标记,并结合分水岭算法实现了细胞核分割。他们进一步融合趋势与非趋势特征评分模型,并结合马尔科夫模型利用上下文延时数据,实现对细胞相位的准确识别。这一研究展示了分水岭算法与时间序列信息结合的可能性,显著提高了分割的准确度。除此之外,一些改进的分水岭算法也被广泛研究以解决分割失败或过分割的问题。Buggenthin^[13]通过 MSER 检测生成标记,并使用带掩码的分水岭算法分割细胞核拥簇前景,借助掩码提供的先验信息,能够更精确地标记细胞边界。这种方法也存在一定的局限性,例如当标记不准确或先验信息不足时,可能导致分割失败或分割边界不完整。

此外,针对分水岭算法易产生过分割的问题,一些研究通过结合预处理和后处

理方法进行优化。例如，通过高斯滤波平滑输入图像以减少噪声和伪影，或者结合图像梯度信息以生成更为精准的标记区域。此外，将分水岭算法与深度学习方法相结合，例如利用卷积神经网络（Convolutional Neural Networks, CNN）生成种子点标记，也成为当前研究的热点方向。类似地，区域生长法为另一种传统的基于像素相似性的分割方法^[14]，同样面临种子点选择敏感、易受噪声影响等问题。因此，研究者也在探索将深度学习与区域生长法结合，例如通过深度神经网络学习最优种子点，或利用自适应相似性度量提高分割的鲁棒性^[15]。有学者^[16]提出了一种基于自动多种子区域生长的遥感影像面向对象分割方法，通过自动选取种子点，提升了算法在复杂遥感影像中的分割效果。此外，另一项研究^[17]提出了一种基于多尺度的区域生长图像分割算法，通过在不同尺度下进行区域生长，增强了算法对医学图像的适应性。

综上，传统方法在细胞核分割早期应用中发挥了重要作用，但在处理高重叠、高变形等复杂图像时，存在边界模糊、鲁棒性差等问题。随着深度学习的发展，数据驱动的方法逐渐成为主流，但传统方法中的边缘建模等思想仍具启发性。将其优势与现代网络结构结合，仍是提升分割性能的有效路径，也为本文方法的设计提供了重要参考。

1.2.2 基于深度学习的分割方法

基于深度学习的分割方法近年来成为细胞核分割领域的研究热点，并取得了显著的成果。与传统方法不同，深度学习能够自动学习数据驱动的特征，避免了手动设计特征的局限性，并在各种真实病理数据集上展现出稳定的性能提升。因此，深度学习已成为当前细胞核分割领域的主流技术，并在临床应用中取得了显著进展。根据模型设计不同，细胞核分割方法大致可分为自顶向下和自底向上两类。

（1）自顶向下的方法（如 Mask R-CNN^[18]）在自然图像分割任务中取得了显著进展。然而，在细胞核分割任务中的应用仍面临诸多挑战^[19-22]，主要体现在以下两个方面：首先，在数据层面，组织病理图像中细胞核往往存在严重的重叠现象。传统的单一边界框方案通常包含多个边界模糊的细胞核，这不仅增加了网络优化的难度，还可能导致多个细胞核被归为同一实例，从而降低分割的精确度。此外，由于边界框难以精确适应单个细胞核的形态特征，这进一步增加了分割任务的复杂性，影响单核识别的准确性。其次，在模型方面，自上而下的方法通常以固定的分辨率预测分割蒙版（例如， 28×28 ），然后重新采样这些蒙版以匹配其相应的边界框的大小。这种重采样过程会引入量化误差^[19]，给细胞核边界的准确分割带来挑战。

（2）自底向上方法由于精度高，在细胞核实例分割中得到了广泛的应用。自底向上的方法首先回归各种类型的核代理，然后使用细粒度的后处理将像素分配

给各个实例。这些方法通常涉及设计鲁棒的网络架构^[20-25]，结合辅助任务学习，并提出优化的分割策略。具体来说，DIST^[25]通过预测每个像素到其相关细胞核中心的距离，将核分割问题转化为距离图回归。沿着预定的一组方向，StarDist^[21]及其扩展 CPP-Net^[26]预测每个前景像素与其相应实例边界之间的距离。CIA-Net^[22]通过增加额外的轮廓监督来增强核分割的信息丰富度。为了提高分割效率，Triple U-Net^[27]创建了一个并行的特征聚合网络，将 RGB 和苏木精图片的特征结合起来。CD-Net^[28]利用向心方向来描述核内的空间关系，有效地识别边界。通过估算核像素与质心之间的垂直和水平距离，Hover-Net^[29]是第一个同时提出核分割和分类的模型。Schmidt^[30]提出用星形凸多边形代替边界框来定位，为重叠核和聚集核的分割提供了新的解决方案。

除了自顶向下和自底向上两大分类外，细胞核分割方法还可以从网络结构的角度进行划分，主要包括单路径和多路径方法。

(1) 单路径方法采用单一主干网络进行特征提取和分割预测，因其结构简洁、计算效率高，在细胞核分割任务中得到了广泛应用。例如，基于 U-Net 及其变体（如 Dense-UNet^[31]、Swin-UNet^[32]）的模型，能够通过编码器提取多尺度特征，并利用跳跃连接逐步恢复空间信息，从而实现较为精准的分割。此外，一些回归式方法，如 DIST 通过预测像素到细胞核中心的距离，将实例分割问题转换为距离图回归，有效地减少了细胞核粘连问题。该方法通过预测每个像素到细胞核质心的距离图，减少了传统分割方法中常见的边界不清晰问题，尤其适用于细胞核重叠和接触较多的情形。StarDist 进一步扩展了这一思想，提出了一种基于放射状方向的距离预测机制。通过在像素层面预测多个方向的距离，StarDist 能够更精确地估计细胞核的边界，尤其是在细胞核形态不规则或边缘模糊的情况下，表现出色。该方法通过多角度的距离预测，可以有效处理复杂的细胞形态和结构，尤其在面对高度重叠的细胞核时，能够提供更精确的分割边界。

(2) 相比之下，多路径方法通过多个分支并行学习不同层次的信息，并在解码阶段进行特征融合，以增强分割的精度和鲁棒性。此类方法能够充分利用边界信息和局部细节，从而在高重叠和复杂形态的细胞核分割任务中展现更强的适应性。例如，CIA-Net 通过引入轮廓感知分支（Contour-aware Branch）强化了模型对细胞核边界的识别能力，并设计了平滑截断损失函数（Smooth Truncated Loss）以减弱噪声标签的影响，提升模型在复杂背景下的泛化能力。Hover-Net 通过额外预测水平-垂直距离和细胞核类别信息，实现了更精确的实例分割与分类。BESNet^[24]采用双解码器结构，一条路径用于恢复图像分辨率，另一条路径用于增强边界信息，从而优化整体分割质量。此外，CellViT^[33]基于 Vision Transformer (ViT)^[34]的方法通过长程依赖建模能力提升了对全局信息的理解，并通过多尺度特征的有效整合，显著提升了分割精度。

综上，单路径方法计算高效、易训练，但是对细胞核边界利用不足，易导致边缘模糊，难以区分高重叠、高变形细胞核。多路径方法在分割精度和边界识别上具备优势，但模型复杂且参数较多，容易从训练数据中记忆细节，而没有学习到可泛化的特征。针对上述问题，本文提出了一种多维度点线面融合结构（Spot-Edge-Surface Network, SES-Net）和文本提示的细胞核分割模型（CLIP-driven Refined U-Net, CRU-Net），从结构设计和特征融合方式两方面突破现有方法的局限性。相比传统单路径模型，SES-Net 引入了边缘与点的显式引导机制，使模型在保持计算效率的同时，具备对核边界的敏感感知能力；相比现有多路径方法，本文所提方法通过精简设计与融合策略，在确保分割精度的前提下，有效控制了模型复杂度。此外，本文首次将图文大模型 CLIP 引入细胞核分割中，结合语义描述辅助判别复杂结构细胞，实现从分类到分割任务的有效迁移，体现了方法的跨模态创新性。

1.3 本文主要研究内容

本文以数字病理图像为研究对象，重点探讨深度学习方法在计算病理学中细胞核分割任务中的应用。研究内容涵盖卷积神经网络、特征融合、多任务学习、多模态融合等深度学习技术，以及边缘检测、形态学操作、区域生长法等图像预处理与后处理技术。本研究的核心目标是提出一种能够有效解决数字病理图像中细胞重叠以及模型泛化能力等挑战的自动分割方法。具体的研究内容包括：

（1）针对病理图像中细胞核相互重叠、边界模糊的问题，本文提出了一种新颖的基于点线面特征融合的细胞核实例分割算法。该网络采用三支结构，分别聚焦于细胞核的关键点、边缘和区域特征，能够有效地捕捉细胞核的多维信息。本章还提出了区域优化模块（Region Optimization Module, ROM），通过整合关键点和边缘特征，优化分割掩码，进而提高分割精度。实验表明，SES-Net 在 MoNuSeg、CoNSeP 和 CPM-17 公开数据集中 Dice 系数分别达到了 0.837、0.865 和 0.880。在保持较高分割精度的同时，显著提高了推理速度，展示了其在计算效率和分割性能之间的优良平衡。消融实验表明，点、线、面信息的联合学习对提升分割精度至关重要，而 ROM 有效优化了实例边界，增强了分割结果的细致性。该算法为细胞核实例分割任务提供了新的解决方案，展现了良好的鲁棒性和精度，未来有望在更多医学图像分割任务中取得突破。

（2）针对传统多路径结构在细胞核分割中存在的特征竞争和泛化能力不足的问题。本文提出了一种基于密集连接网络与文本提示的细胞核分割算法。该方法采用单一路径结构，通过引入 CLIP 模型的语义信息，为每个细胞核图像提供文本描述，从而为模型注入细胞核的语义先验知识。该模型在 U-Net 架构的基础上，设计了密集连接网络结构，并通过密集的下采样和上采样路径优化了细胞核边缘区域

和小目标的分割效果。此外，跨模态跳跃连接的引入，使得图像和文本特征能够动态交互，通过计算图像和文本之间的相似性，优化特征的注意力分配，增强了模型的细节捕捉能力。在编码器瓶颈处，引入了跨模态融合模块，通过跨模态特征融合实现了文本和图像特征的对齐。实验结果表明，该算法在 MoNuSeg 和 CoNSeP 数据集上的 Dice、AJI 和 PQ 指标均有显著提升，尤其是在跨数据集验证中，最大提升分别为 12%、4% 和 12.5%。与传统的多路径模型相比，显著提高了模型的分割精度和泛化能力。

1.4 论文的组织结构

本文共分为五个章节，每个章节的具体内容安排如下：

第 1 章，绪论。本章主要介绍了论文的研究背景及意义，通过数据介绍了癌症在全中国以及世界范围内的患病情况，并分析了目前使用传统分割技术以及深度学习算法对细胞核分割研究的现状，阐述了数字病理分析在临床决策的重要性，重点梳理了细胞核分割的国内外研究现状以及目前存在的问题，从而确立了本文的研究方向。最后总结本文的主要研究内容，并提出论文的组织结构。

第 2 章，相关知识介绍。本章主要从三个方面对背景知识进行介绍：首先介绍数字病理图像相关知识；其次介绍基于深度学习的细胞核分割相关技术其中包括 U 型编码-解码网络、多任务学习在细胞核分割中的应用与 CLIP 在医学图像分析中的应用。

第 3 章，本章介绍了一种基于点线面特征融合的细胞核实例分割算法。该方法包含关键点检测、边界检测和掩码预测分支的三支网络结构，该结构增强了边界信息监督显著提高了核分割性能。接着提出了一个区域优化模块，通过结合每个核实例的关键点和边界来提高预测位置的准确性。最后提出了一种后处理策略，利用多维特征来有效地纠正错误的分割和多余的分割。

第 4 章，本章介绍了一种基于密集连接网络与文本提示的细胞核分割算法。该方法引入 CLIP 模型的语义信息为细胞核分割提供医学文本提示，并在 U-Net 架构中设计密集连接，增强了特征的重用能力并有效融合了语义信息。在编码器瓶颈层设计跨模态融合模块，融合了文本和图像特征，进一步提高了分割性能。同时，在跳跃连接结合跨模态注意力机制，动态调整图像特征的注意力权重，优化了跳过连接，使得分割结果能够更精准地反映文本语义信息。

第 5 章，本章对全文进行了总结，并展望了未来的研究方向。首先，回顾了本文的主要工作，首先针对现阶段存在的挑战，如模型泛化能力、细胞重叠等问题，提出了创新方法。最后，展望了细胞核分割任务的未来研究，包括提升分割精度、增强模型鲁棒性及多模态融合等方面的潜力。

第 2 章 相关知识介绍

2.1 数字病理图像相关知识介绍

数字病理图像是通过将传统病理切片图像进行扫描生成高分辨率数字图像而得到的，这一技术被广泛应用于医学领域，特别是在肿瘤学、免疫学等领域的诊断中。与传统的显微镜观察病理切片不同，数字病理图像具有更高的存储、共享与处理能力，能够极大提高病理学分析的效率与准确性。这一技术的发展极大地推动了病理学诊断和研究的数字化进程，为精准医学提供了重要的工具。许多医学影像技术（如 CT^[35]、B 超^[36]和磁共振成像 MRI^[37]）依赖于外部介质与人体组织的相互作用，以间接方式获取人体内部器官的影像。CT 为通过测量不同组织对 X 射线的吸收程度，获得立体图像；B 超通过分析不同组织对声波的反射与吸收来成像，主要用于软组织检查；而 MRI 则利用人体内原子核的自旋特性，在磁场和射频脉冲的作用下产生图像。与这些技术不同，病理切片是通过直接获取组织样本并进行显微切割得到的。这些切片是物理存在的，能够精准展现组织的微观结构，而非电子成像。在制作病理切片的过程中，组织经过一系列处理步骤，包括脱水、浸蜡、染色等，以保存组织的细节并提高可视化效果^[38]。常用的苏木精-伊红（Hematoxylin and Eosin, H&E）染色法能够将不同类型的组织染成不同的颜色，便于显微镜下的观察。制作完成后，病理切片用于病理医生的诊断分析，为疾病的判断提供依据。

病理组织切片制作流程如图 2.1 所示，整个过程包括多个关键步骤：首先，医生从患者体内获取组织样本，通过穿刺、切取等方式从肿瘤或疑似病变区域获得组织样本。接下来，实验室对采集到的组织样本进行脱水、浸蜡等预处理，并使用 H&E 染色法进行染色，使组织的不同部分呈现不同的颜色，便于在显微镜下分辨和分析。最后，完成染色后，组织被封固并制成病理切片，供病理医生进行疾病诊断。




图 2.1 病理组织切片制作流程

随着病理学的发展,传统切片因易碎、存储和传输不便,以及长时间显微镜观察带来的疲劳和主观性影响,逐渐暴露出局限^[39]。在数字化的今天,病理切片还可以通过计算机扫描转换为高分辨率的数字图像,即全切片扫描数字病理图像(Whole Slide Image, WSI)^[40],并通常采用多分辨率金字塔结构进行存储。该过程确保了病理图像的高质量 and 便于数字化分析,同时,染色操作在其中起到了至关重要的作用,因为它能够使组织在显微镜下呈现出清晰的结构特征,辅助病理诊断。WSI 是通过高分辨率的计算机扫描技术,将传统病理切片转化为数字病理图像,它能够保留组织切片的所有细节,提供丰富的病理信息,且由于其数字化特点,便于存储、共享和传输。常见的 WSI 格式包括.svs 和.tiff 等,它们通常采用金字塔式结构进行存储,即在不同分辨率层次上叠加图像,以形成完整的图像文件。由于这一存储方式导致 WSI 图像的文件体积较大,单张全扫描图像的存储大小通常在 500MB 到 3GB 之间。图 2.2 展示了全切片数字病理图像的存储结构。




图 2.2 全切片数字病理图像存储结构

数字病理图像与常见的自然图像相比,具有几个显著的特点:

(1) 巨大空间尺寸: 数字病理图像通过高倍显微镜扫描获得,其空间尺寸远超普通图像。相比其他成像方式,组织切片的数字图像往往包含数以百万计的像素,呈现出复杂的细胞结构和丰富的生物学信息。这种高分辨率使得深度学习模型难以直接处理整张图像,通常需要对图像进行裁剪,选择适当的尺寸进行处理。

(2) 显著的外观变化: 数字病理图像的外观受制于多种因素,包括样本准备、扫描设备和图像采集的物理环境。例如,不同的染色方法、设备差异以及时间因素都会导致颜色变化。此外,数字化过程中,照明条件和压缩存储等因素也可能引起图像色差,这使得图像的外观在不同实验中存在较大的差异。

(3) 高昂的标注成本: 在计算病理学任务中,大量的标注数据对训练深度学习模型至关重要。然而,图像标注是一个繁琐且技术要求高的过程,通常需要病理

学家和机器视觉专家的参与，耗费大量时间和精力。这种高成本限制了可用数据的数量，并推动了弱监督学习和半监督学习方法的发展，旨在减少对标注数据的依赖。

综上，数字病理图像的这些特点不仅揭示了其本身的复杂性，也为计算病理学模型的研究和应用带来了挑战。为了应对图像尺寸问题，通常会将大图像裁剪成较小的块进行处理。针对外观变化，常通过染色标准化等预处理方法加以调整。而为了解决标注难题，研究者探索了半监督学习和主动学习等方法，以提高数据的利用效率。

在病理学研究与疾病诊断中，病理图像是通过显微镜拍摄的组织切片图像，可提供丰富的组织形态、细胞结构及疾病状态信息。其中，细胞核作为细胞的核心结构，承载着遗传信息，直接影响细胞的生长、分裂及功能状态，是判断细胞健康状况的关键因素。在病理图像分析中，细胞核的形态、大小、数量、染色特征及空间分布等信息，往往是区分正常细胞与病变细胞的重要依据。例如，直肠腺癌细胞核如图 2.3 所示，通常呈现形态不规则、大小分布不均、核质比异常增大的特征，并伴随染色深浅不均的现象。这些细胞核图像特征为医生提供了诊断恶性肿瘤的重要生物学线索。细胞核的精准分割与分析不仅能够辅助识别病变区域，还可用于评估疾病的进展与恶性程度，在现代计算病理学中发挥着核心作用。




图 2.3 直肠腺癌细胞核

因此，细胞核在病理图像分析中的重要性日益凸显，自动化细胞核分割技术已成为该领域的关键研究方向。精准的细胞核分割与分析不仅为疾病的早期诊断和治疗方案的制定提供了有力支持，还能有效降低人为因素对诊断结果的影响。结合深度学习技术的自动化细胞核分割方法，能够进一步提升分割精度，减少人工干预，从而提升病理学诊断的效率与可靠性，推动计算病理学的进一步发展。

2.2 基于深度学习的细胞核分割相关技术

细胞核分割是病理图像分析的核心任务，也是肿瘤微环境（Tumor Microenvironment, TME）研究的基础。精准的细胞核分割不仅能够揭示组织结构特

征，还能为肿瘤标志物的识别与探索提供关键数据支撑。然而，传统的细胞核分割方法往往依赖人工设定的参数，在面对复杂的医学图像时，易受噪声干扰、形态变化及组织异质性的影响，导致分割精度下降无法满足实际应用需求。

近年来，随着深度学习技术的发展，基于神经网络的细胞核分割方法得到了广泛关注，并在分割精度、泛化能力和鲁棒性方面取得了显著进展^[41]。典型的深度学习分割模型包括卷积神经网络、U 型编码-解码结构（如 U-Net 及其变体）、多任务学习网络，以及结合 CLIP 等跨模态技术的模型。本文将对这些主流深度学习分割方法进行系统性探讨，并分析其在细胞核分割任务中的优势与挑战。

2.2.1 卷积神经网络

目前，医学图像分割中广泛采用的卷积神经网络，如 U-Net^[42]，都是在传统 CNN 基础上不断演进而来的。它是一种专为处理空间数据（如图像、视频）设计的深度神经网络，广泛应用于图像分割、目标检测和语音识别等任务。其主要由输入层、隐藏层和输出层组成。其中，隐藏层进一步包含以下关键组件：卷积层、池化层、激活层和全连接层。卷积神经网络结构如图 2.4 所示。




图 2.4 卷积神经网络结构

（1）卷积层：负责从输入数据中提取特征。其通过卷积核以滑动窗口方式对输入进行加权求和，生成特征图，从而捕捉空间局部结构。卷积层通过参数共享机制显著减少网络参数，有效缓解过拟合并提升模型泛化能力。不同尺寸的卷积核可适配多种任务需求，实现对不同尺度特征的提取。如图 2.5 所示，采用 3×3 卷积核、步长为 1 对 4×4 输入特征图进行卷积，可获得尺寸为 2×2 的输出特征图^[43]。




图 2.5 卷积操作过程

(2) 池化层：在 CNN 中的作用是降低特征的空间尺寸，从而达到减少网络模型中参数的数量以及模型的计算复杂度^[44]。利用池化层对特征实现降维操作能够提高模型的泛化能力，防止模型在训练过程中出现过拟合的现象。CNN 中的池化层结构分为平均池化层和最大池化层两种类型，如图 2.6 所示。




图 2.6 池化操作

最大池化通过提取滑动窗口覆盖区域中的最大值，有效保留显著特征，具备一定的平移不变性，适用于图像中目标存在偏移的情况，因而广泛应用于目标识别等任务中。平均池化则计算窗口内所有像素的平均值，更适合保留整体背景信息，常用于处理纹理平滑的图像。两者在特征选择上各有侧重，实际应用中可根据任务需求灵活选择^[45]。

(3) 激活层：激活层在 CNN 中主要用于引入非线性因素，使得网络能够学习到更复杂的特征。激活层的作用是在每个神经元输出值上应用一个激活函数，从而决定神经元的激活程度，进而影响后续层的学习。激活函数能够增加网络的表达能力，使其能够适应更多复杂的模式和关系^[43]。常见的激活函数包括 ReLU、Sigmoid、Tanh 等，计算过程如下：

$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2.1)$$

$$\text{ReLU}(x) = \max(0, x) \quad (2.2)$$

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.3)$$

激活函数不仅决定了神经网络的非线性表达能力，还直接影响训练效率和最终模型的性能。通过逐层叠加激活函数，神经网络可以实现多次非线性变换，从而学习数据的深层特征，进一步提升对复杂任务的建模能力。

(4) 全连接层：在全连接层中，神经元与前一层的所有神经元相互连接，以实现特征整合和信息传递。通过这种方式，网络能够结合来自不同区域的特征，学习到数据的全局模式。在分类任务中，经过全连接层的输出通常通过 Softmax 函数进行归一化，转换为概率值，最终选取最大概率对应的类别作为分类结果^[46]。

Softmax 函数的计算公式如下：

$$y = f(Wx + b) \quad (2.4)$$

在全连接层中，上一层的输出值 x 与权重矩阵 W 进行加权求和，再加上偏置向量 b ，然后通过激活函数 f 进行非线性变换，最终得到当前层的输出。

2.2.2 U 型编码-解码网络

尽管 CNN 已经成为图像分析领域的核心技术，但在处理医学图像中尺度较小、形态复杂的目标时（如细胞核、微小病灶），仍面临着精度和细节恢复的挑战。为了解决这些问题，U-Net 模型应运而生，并且逐步发展成为了医学图像分割中最具影响力的架构之一，并衍生出众多变体模型，被广泛应用于器官分割、病灶检测和细胞结构分析等各类场景中^[47-49]。

U-Net^[42]如图 2.7 所示是一种经典的医学图像分割模型，其采用了编码器-解码器（Encoder-Decoder）结构。该架构首先通过编码器将输入图像逐步压缩成低维的特征表示，提取出图像中的重要信息。接着，解码器对这些低维特征进行逐步解压，以恢复图像的空间分辨率并生成分割结果。与传统的编码器-解码器网络不同，U-Net 通过其独特的跳跃连接（skip connections）设计，实现了编码器与解码器之间的高效特征融合。这些跳跃连接将编码器中各层的特征图直接传递到解码器相应层，从而保留了图像的细节信息，同时结合了高层次的语义信息。这种设计使得 U-Net 能够在处理医学图像时有效结合局部细节与全局上下文信息，显著提高了图像分割的精度。跳跃连接帮助模型更好地恢复图像细节，尤其在处理边界模糊或目标小且形状复杂的医学图像时，能够有效地减少信息丢失。此外，U-Net 的这种结构

还具有较强的鲁棒性，能够适应不同的图像分割任务，从而广泛应用于医学图像、卫星图像、遥感图像等多个领域。




图 2.7 U-Net 网络结构

Dense-U-Net^[31]如图 2.8 所示是对传统 U-Net 架构的一种改进，它引入了密集连接网络（DenseNet）结构的思想。DenseNet 本质上是通过在每一层中将前面所有层的输出作为输入来加强特征传递，从而增强特征的复用性和信息流动。Dense-U-Net 在 U-Net 的基础上，将每一层的输出与其前面所有层的输出连接起来，从而增强了网络的信息流动性和特征表示能力。在 Dense-U-Net 中，编码器和解码器都采用了密集连接（dense connections）。具体而言，每个卷积块不仅将当前层的输入信息传递到下一层，还将所有之前层的输出信息进行连接并传递给下一层。这种密集连接设计使得 Dense-U-Net 能够充分利用低级到高级的特征信息，有效提高了模型的表现。

尽管 U-Net 及其变种在医学图像分割中表现优异，但在处理细胞核与边缘区域紧密联系、形态复杂或背景噪声较强的图像时，现有模型仍面临一定挑战^[50]。为此，Kumar 等人^[51]提出了一种改进的 U-Net 结构，针对细胞核分割问题进行了优化。该模型通过增强对边缘信息的提取能力，显著提高了细胞核与背景之间的区分效果。具体来说，该方法引入了边缘特征，并与图像整体特征相结合，有效改善了细胞核及肿瘤边界的分割精度，尤其在细胞核与背景或边缘区域重叠的情况下，分割结果更加准确。

综上，U-Net 及其变种在医学图像分割任务中展现出了卓越的性能，特别是在细胞核、肿瘤、器官等结构的分割中。然而，面对细胞核与边缘区域紧密连接以及复杂背景的挑战，现有的 U-Net 架构在某些任务中仍然存在一定的局限性，亟需进

一步的改进与优化。




图 2.8 Dense-U-Net 网络结构

2.2.3 多任务学习

多任务学习（Multi-Task Learning, MTL）的概念最早由 Caruana 于 1993 年提出^[52]。这一方法不仅包含模型架构的设计，也包括训练过程中的任务划分、损失函数定义和优化策略等方面。具体地，多任务学习通过共享底层网络架构来实现任务间的信息传递与知识共享，从而提高每个任务的学习表现。与单任务学习相比，它能够共享多个任务的模型空间，这不仅加速了训练过程，还增强了模型的泛化能力。

在细胞核分割任务中，由于细胞形态的多样性、背景的复杂性以及细胞核与背景之间的模糊边界，传统的单任务学习方法在准确度和鲁棒性上往往存在局限性。为了克服这些挑战，多任务学习被广泛应用于细胞核分割任务，通过同时解决多个相关任务，提高分割性能^[53-54]。多任务学习通过共享网络的部分层，使得不同任务可以共享信息，从而帮助模型学习到更具泛化能力的特征。

(1) CIA-Net^[22]如图 2.9 所示，是一种基于多层信息聚合的多任务学习细胞核分割框架，在医学图像中尤其是细胞核结构复杂、边界模糊的场景下展现出了优越的性能。该网络在设计上引入了两个主要改进：一方面，通过多任务学习策略，联合优化细胞核的分割与边界检测任务，实现了特征层级之间的信息协同，从而增强了模型对细粒度边缘特征的识别能力。另一方面，CIA-Net 提出了平滑截断损失函数（Smooth Truncation Loss），该损失函数在传统损失的基础上引入了对异常值的抑制机制，能够有效减少噪声样本或错误标注对模型训练过程的干扰，显著增强了模型在复杂图像背景中的鲁棒性与泛化能力。

此外，CIA-Net 通过深层特征融合策略实现了对图像不同尺度和语义层次的充分感知，使模型在细胞核边缘模糊、形态不规则或存在重叠的区域，仍能保持较高的分割精度。该方法在面对不同数据源或组织类型时依旧保持稳定表现，展示出强

大的跨域适应能力。这一研究充分说明了多任务学习框架与针对性损失函数设计在提升医学图像分割模型性能方面的重要价值。




图 2.9 CIA-Net 网络结构

（2）Hover-Net^[29]如图 2.10 所示，是一种面向细胞核分割与分类的多任务学习模型，在结构设计与信息建模上均展现出较强的创新性。该方法通过联合执行重叠细胞核的实例分割与核类别识别两个任务，不仅提升了模型的整体性能，还增强了对复杂组织结构中细胞核间差异的建模能力。HoVer-Net 的核心思想在于引入了“Horizontal and Vertical”距离映射（即 HoVer 映射），即对每个像素预测其到所属细胞核质心的水平和垂直距离信息，从而显式建模细胞核内部的空间结构与轮廓方向。这种距离编码在训练阶段能够引导模型学习到更加准确的空间关系，特别适用于细胞核密集、形态重叠严重的病理图像分割任务。




图 2.10 Hover-Net 网络结构

此外, HoVer-Net 架构中包含三条解码路径, 分别用于细胞核分割、HoVer 距离回归和细胞核分类任务。多任务学习策略使得模型能够在共享底层特征的基础上, 实现对不同任务特定信息的精准建模。通过分支之间的协同优化, HoVer-Net 有效缓解了信息冗余与特征冲突问题, 提升了模型在边界模糊、核体密集和异质性较强区域的鲁棒性。

近年来, 多任务学习在医学图像分割领域取得了显著进展, 尤其在语义分割、目标检测等任务中得到了广泛应用。例如, Li 等^[55]则提出了一种结合低频和高频图像分量的多任务学习方法, 在该方法中, 语义分割网络输出的高语义层次特征图被解耦为主体特征和边界特征两部分。通过不同的损失监督对这两部分特征进行调优, 再结合优化后的特征来生成最终的语义分割结果, 同时引入难例挖掘策略进一步提升分割性能。Meta-MTL^[56]模型利用元学习和多路径学习来促进任务之间的特征交换, 从而降低细胞核分割的训练样本要求。DoNet^[57]通过分解和重组策略以及掩码引导的区域建议策略有效地解决了细胞实例分割中的重叠和混淆问题。

CIA-Net 与 HoVer-Net 均通过多任务学习策略, 在提升细胞核分割精度和鲁棒性方面取得了显著进展。两者在不同设计思路下, 分别增强了模型对细胞核边界信息与空间关系的建模能力, 尤其在面对细胞重叠、形态复杂及背景噪声较多的病理图像时, 表现出更强的适应性与泛化能力。这些方法表明: 通过任务间的协同优化与特征信息的有效融合, 是当前提升细胞核分割性能的重要方向。

2.2.4 CLIP

CLIP (Contrastive Language-Image Pre-Training) 模型是一种多模态预训练神经网络, 由 Open AI 在 2021 年发布, 是从自然语言监督中学习的一种有效且可扩展的方法^[58]。其核心理念为图文对比学习预训练, 是一种多模态学习模型, 旨在将图像和文本进行关联, 它可以快速实现图文特征相似度计算、跨模态检索、零样本图片分类等任务。与传统视觉模型依赖标注图像不同, CLIP 利用来自网络的 4 亿对弱监督图文数据 (如图片与标题) 进行预训练, 以学习图像与文本之间的对应关系。相比复杂的多模态预训练方法, CLIP 采用了简洁高效的双编码器架构, 包括文本编码器和图像编码器。文本编码器将文本转换为低维向量表示, 而图像编码器则将图像转化为对应的向量表示, 从而使得图像和文本能够在同一嵌入空间内进行对齐和匹配。CLIP 的架构与训练方式如图 2.11 所示。

预训练阶段的输入为图文配对数据, 其中每张图像对应一段简短的描述性文字。图像和文本分别通过各自的编码器编码为向量表示, 用于学习二者之间的语义关联。这里的文本编码器是 Bert, 而图片编码器是 Resnet 或者是 VIT。CLIP 的架构其实是非常简单的, 就是两个编码器组合起来通过对比学习来训练, 但是它无监督训练了 4 亿+的文本对, 通过大数据堆叠出来了模型的性能以及 Zero-shot 能力。




图 2.11 CLIP 架构以及训练思路

图像编码器采用两种架构：一种基于 ResNet-50，并结合 ResNetD 改进和抗锯齿的 Rect-2 模糊池对其进行了优化，同时将全局平均池化替换为注意力池化机制。该机制使用单层多头注意力，其中查询（Query）由图像的全局平均特征生成。另一种架构则基于 Vision Transformer（ViT），仅在 Transformer 之前添加了层归一化，并采用了略微不同的初始化方式。ViT 网络结构^[34]如图 2.12 所示。




图 2.12 ViT 网络结构

首先对图片进行分块 patch，并加入位置信息，将特征图展开为序列，输入到 transformer 编辑器中进行特征提取，通过自注意机制关注每个图像块的重要程度；其自注意结构根据查询、键、值（这三个处理通过对输入的线性变换的到）得到输出，公式如下：

$$Atteintion(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_K}}\right)V \quad (2.5)$$

文本编码器是 Transformer 架构^[59]如图 2.13 所示，并在此基础上根据 Radford 模型进行了架构修改。作为基础尺寸，文章使用 12 层 512 宽的模型，有 8 个注意力头。文本编码器首先对输入文本进行小写字节对编码（BPE），并在序列两端添加 [SOS]和[EOS]标记。Transformer 对该序列进行编码，其最高层在[EOS]位置的激活（经过层归一化）作为文本的整体表示，并通过线性投影映射到多模态嵌入空间。此外，编码器内部采用自注意机制，以保留引入语言建模作为辅助任务的能力。




图 2.13 Transformer 架构

基于 CLIP 的模型近年来在医学图像分割中表现出了强大的潜力，尤其是在多目标、多类别的图像分割任务中。CLIP 模型通过联合学习图像和文本的表示，可以有效捕捉图像的语义信息，并将其与文本描述中的语义联系起来，从而提升了模型对图像内容的理解能力^[60-63]。Liu 等人^[70]提出了一种基于 CLIP 的通用模型（CLIP-Driven Universal Model），如图 2.14 所示，该方法通过引入自然语言描述与视觉图像之间的对比学习机制，实现了文本-图像的跨模态融合，以构建一个具备更强泛化能力的通用分割模型。该方法的核心设计理念为：利用 CLIP 模型中训练得到的文本嵌入（text embeddings）作为分割模型的标签语义表示，以替代传统 one-hot 编码或类别索引。这种基于语言的标签建模方式，能够捕捉器官与肿瘤间的语义关系和解剖结构约束，为模型提供了更丰富的结构先验知识，尤其适用于数

据标注不全、任务边界不明确的场景。

该方法的核心设计理念为：利用 CLIP 模型中训练得到的文本嵌入作为分割模型的标签语义表示，以替代传统 one-hot 编码或类别索引。这种基于语言的标签建模方式，能够捕捉器官与肿瘤间的语义关系和解剖结构约束，为模型提供了更丰富的结构先验知识，尤其适用于数据标注不全、任务边界不明确的场景。

从模型架构上看，CLIP-Driven Universal Model 采用编码器-解码器结构作为基础框架，引入语言引导模块，使得模型在图像特征提取阶段即可融合与目标类别相关的语义信息。其中文本嵌入向量与图像特征通过注意力机制进行对齐，增强了模型对解剖结构和病灶区域的语义理解能力。此外，该方法还设计了跨数据集训练机制，利用来自 14 个公开数据集的 3410 例 CT 扫描图像进行联合训练，并在来自多个医疗中心的 6162 例 CT 图像上进行泛化测试，涵盖了 25 类器官和 6 种类型的肿瘤。




图 2.14 基于 CLIP 的医学通用模型

MedCLIP^[61]作为 CLIP 的一种扩展，结合了图像和文本的特征，通过替换传统的 InfoNCE 损失函数为语义匹配损失，显著提升了模型在零样本学习、监督分类以及图像-文本检索任务中的表现。这一方法的成功使得 CLIP 模型在图像与文本的联合学习中展现出了巨大的潜力，尤其在医学图像分析中，能够有效地提高模型对不同医学任务的适应性。为了克服这一问题，Ye 等人^[63]提出了一种基于提示的通用分割模型，该模型利用任务之间的相关性和共享特征，通过提示增强模型对任务的“感知”能力。这种方法的核心在于通过任务间的相关性，提前让模型理解当前任务的特征，从而有效提高分割的性能。该模型尤其适用于细胞核分割任务，通过细胞核和背景、边缘之间的语义关系，能够提高分割的精度，尤其在细胞核与背景之间边界模糊的情况下。

综上，尽管 CLIP 模型在多目标、多类别的医学图像分割中表现出色，但由于细胞核和边缘之间的紧密联系，现有的基于 CLIP 的模型仍然难以有效分离细胞核

图像的不同特征。这一问题的根源在于细胞核和背景、边缘的过渡区域非常模糊，传统的 CLIP 文本提示难以精准地捕捉这种微妙的差异，因此，在细胞核分割中仍需要引入更多的策略来改善模型的性能。

2.3 细胞核分割数据集介绍

本次研究在三个公开的细胞核分割数据集上进行了实验评估，分别包括：多器官细胞核分割数据集（Multi-Organ Nuclei Segmentation dataset, MoNuSeg）^[51]、结直肠癌核分割表型数据集（Colorectal Nuclear Segmentation and Phenotypes dataset, CoNSeP）^[29]以及 CPM-17 分割数据集^[20]。数据集摘要如表 2.1 所示，数据集部分图像如图 2.15 所示，具体介绍如下：

（1）MoNuSeg 数据集是由 MICCAI2018 多器官细胞核分割挑战赛提供的。该数据集汇集了来自 18 家不同医院的 16 位患者的病理细胞核图像，累积了超过 21000 个细胞核的注释信息。该数据集涵盖了 44 张经过 H&E 染色的癌组织病理图像和对应的细胞核标签，每张图像的尺寸均为 1000×1000 像素，图像放大倍率为 40×。在训练集中，图像样本来源于不同病人的七种器官，包括乳腺、肾、肺、前列腺、膀胱、结肠和胃，覆盖了九种不同类型的癌症，总计 30 张图像。

（2）CoNSeP 数据集是一个包含 41 个 H&E 染色图像块的数据集。每个图像块的尺寸为 1000×1000 像素，并且使用 40×的物镜放大倍率。这些图像块是从 16 个结直肠腺癌（CRA）WSI 中提取的。每个 WSI 都对应一个患者，并且使用英国考文垂大学医院和沃里克郡大学医院病理学系的 Omnyx VL120 扫描仪进行扫描。


（3）CPM-17 数据集是一个公开的医学图像数据集，专注于细胞核实例分割。该数据集包括 64 张经过苏木精-伊红（H&E）染色的高分辨率病理图像，分为 32 张训练集和 32 张测试集。图像来源涵盖四种脑癌类型：非小细胞肺癌、头颈部鳞状细胞癌、胶质母细胞瘤和低级别胶质瘤。每张图像的分辨率为 500×500 或 600×600 像素，扫描倍率为 20×或 40×。数据集内共标注了 7570 个细胞核实例，为细胞核检测和分割算法的开发提供了高质量的训练与评估数据。

表 2.1 MoNuSeg、CMP-17 和 CoNSeP 数据集摘要


	MoNuSeg	CoNSeP	CPM-17
细胞总数	21623	24319	7570
图像数量	30	41	64
放大倍数	40×	40×	20×/40×

续表 2.1 MoNuSeg、CMP-17 和 CoNSeP 数据集摘要


	MoNuSeg	CoNSeP	CPM-17
图像尺寸	1000×1000	1000×1000	500×500/600×600
细胞种类	8	1	4



(a) MoNuSeg 数据集



(b) CPM-17 数据集



(c) CoNSeP 数据集

图 2.15 数据集部分图像展示

2.4 本章小结

本章主要介绍了细胞核分割任务中的相关理论和技术背景。首先详细介绍了数字病理图像来源与特点；接着展开介绍了基于深度学习的细胞核分割相关技术，其中对 U-Net 网络以及变体做了概述；然后介绍 U 型编码-解码网络、多任务学习和 CLIP 在医学图像分析中的应用；最后，介绍了细胞核分割相关数据集。本章概述了细胞核分割的基础知识与技术，为后续研究奠定了理论基础。

第3章 基于点线面特征融合的细胞核实例分割算法

3.1 引言

在数字病理学范围内，对组织病理学图像进行细胞核图像分割是形态学量化和肿瘤分级评估的基础。细胞核分割的结果可以提供细胞核的基本视觉信息，如大小、形状和颜色，这对理解细胞形态至关重要。因此，这项任务具有十分重要的意义。然而，由于核大小的变化、核边界模糊、染色不均匀、细胞聚集和细胞重叠^[5]等复杂性，核分割带来了相当大的挑战。正如 Schmidt^[30]所讨论的，与自然图像中的物体不同，细胞核通常是重叠的，这使得难以区分相邻的核，并且对于为自然图像设计的实例分割方法（如 Mask R-CNN）缺乏鲁棒性。另一个主要的挑战是细胞核接触之间的边缘模糊，这增加了核分割的难度。研究者已经尝试了许多方法^[22-28]来解决上述挑战，特别是关注编码器-解码器神经结构，U-Net 模型就是一个典型的例子。由于 U-Net 在有效分离复杂组织学图像中紧密定位物体方面的局限性，文献介绍了各种方法，主要集中在三个方面，即设计适当的网络架构，引入辅助任务学习和提出优化的分割策略。然而，这些模型常常缺乏空间意识，难以有效解决复杂病理图像中细胞核重叠和边界模糊的问题。

为了解决上述问题，借鉴日常生活中“从点到线到面”的系统化分层分析思维，提出了一种逐步构建和解析复杂结构的方法，一种全新的多维度基于点线面的网络(Spot-Edge-Surface Network, SES-Net)。该方法采用基于 U-Net 的三支网络结构，由细胞核关键点分支、边界分支和掩码分支组成，利用点、线和面特征来实现细胞核的三维描述。此外，还引入了重叠细胞核实例的区域优化模块（Region Optimization Module, ROM）。该模块以关键点和边界为指导，对重叠的细胞核进行识别和优化。通过后处理策略对分割错误进行校正，得到最终的分割结果。该方法从局部细节细化到整体结构，与传统方法相比，在核实例分割的准确性和鲁棒性方面具有显著优势。该思路不仅提供了一种更加直观且高效的解决方案，同时也增强了模型的可解释性。在生物医学图像分析中，特别是在细胞核特征的描述和分割中，这种思路可以帮助逐步建立一个完整而准确的模型。

3.2 基于点线面特征融合的分割模型

在本章中，提出了一个基于点线面特征融合的细胞核实例分割算法（SES-Net）实现了细胞核实例分割，整体架构如图 3.1 所示。该方法的目标是学习实例的关键

点特征、边缘特征和细胞核特征，首先通过特征提取模块生成三个特征结果：关键点热图、细胞核边缘图和细胞核掩码图。接下来，通过对关键点热图进行高斯滤波并提取局部峰值，每个局部峰值对应一个细胞核实例得到关键点，从而实现了细胞核关键点的检测。然后，在区域优化模块中以细胞核关键点作为种子点，结合核边界信息作为约束，采用区域优化算法对分割结果进行细化与扩展得到优化结果。最后，在优化结果与细胞核掩码之间进行后处理操作，得到最终的分割结果。




图 3.1 SES-Net 网络结构

3.2.1 特征提取模块

在细胞核实例分割任务中，有效的特征提取对于提升检测与分割性能至关重要。传统的骨干网络，如 ResNet^[64]和 VGGNet^[65]，通常采用顺序编码结构，将输入图像逐步转换为高语义但低分辨率的特征表示。这种下采样策略导致空间细节大量丢失，难以保留对小目标（例如小于 8×8 像素的细胞核）的有效信息。因此，传统结构对于小尺度细胞核的检测与分割表现不佳。

为克服上述问题，本章采用高分辨率网络 U-Net 作为特征提取模块的主干架构，特征提取模块如图 3.2 所示。编码器通过多层卷积与下采样提取图像的高级语义特征；解码器则通过上采样操作，并融合来自对应编码器层的特征图，以逐步恢复空间分辨率。该结构能够在保持空间信息的同时学习深层语义特征，从而提高对细粒度目标的敏感性。U-Net 输出的特征图保留了丰富的结构与上下文信息，为后续任务提供了充分的特征支撑。为了实现关键点检测、边缘建模与语义分割的联合建模，进一步在 U-Net 末端引入三个平行的 1×1 卷积层，分别用于预测细胞核关键点热图、细胞核边缘图以及细胞核掩码图。 1×1 卷积有效地对多任务进行解耦，确保各任务共享底层特征的同时，能够独立优化其特定目标。

其中，对于生成的关键点热图，进一步引入局部高斯滤波操作，以提升关键点的定位精度。该操作通过平滑热图，有效减少噪声干扰，使得细胞核中心位置更加准确，有助于后续的实例分割过程。三个任务之间通过协同优化机制相互促进，从

而显著提升细胞核检测与分割的整体性能与鲁棒性。




图 3.2 特征提取模块

3.2.2 关键点检测分支

为了精确地定位每一个细胞核的位置，本章设计了一个关键点检测分支，用于识别图像中每个细胞核的“中心点”。关键点代表细胞核的几何中心，其准确定位能够有效指引细胞核的空间分布，有助于后续的实例分割。这个分支的目标是输出一张与原图大小相对应的热图（heatmap），在热图上，每一个亮点都表示可能存在一个细胞核的中心。亮度越高，表示越有可能是中心，暗的区域则是背景。

具体而言，设输入图像 $I \in \mathbb{R}^{H \times W}$ ，对应的预测热图记作 $\hat{Y} \in \mathbb{R}^{H/R \times W/R \times C}$ ，其中 R 是下采样因子， C 是关键点类型的数量。当只进行核检测任务时，通常设置 $C=1$ ；若同时包含细胞核的分类信息，则 $C > 1$ 。对于每个像素位置 (x, y) 和类别 C ，若预测值 $\hat{Y}_{xyz} = 1$ ，表示该位置检测到类别为 C 的关键点；若为 0，则视为背景区域。

在训练过程中，采用未归一化的高斯核函数构建真实值热图，用于监督模型学习关键点的空间分布^[66]。每个关键点在其中心位置处生成一个响应峰值，其周围根据欧氏距离呈现自然衰减的响应强度。具体公式如下：

$$Y_{xy} = \exp\left(-\frac{(x - \bar{P}_x)^2 + (y - \bar{P}_y)^2}{2\sigma_p^2}\right) \quad (3.1)$$

其中， $(\bar{P}_x, \bar{P}_y)$ 表示关键点的中心坐标， σ_p^2 是与目标尺寸相关的自适应标准差^[67]。决定了高斯分布的扩散程度，用以适配不同尺度的细胞核目标。

为了提升训练稳定性并缓解关键点区域前后景不平衡问题，本分支采用基于焦点损失的关键点损失函数 $\mathcal{L}_{keypoint}$ 。该损失函数强调难分类样本的学习，降低对易分类样本的过度关注，增强了模型在复杂背景下对关键点的识别能力。该分支所生成的关键点不仅准确地标识了每个细胞核的空间位置，同时也为后续区域优化

模块与实例分割的后处理阶段提供了关键信息。具体公式如下：

$$\mathcal{L}_{keypoint} = \frac{-1}{N_{pos}^k} \sum_{xyc} \begin{cases} (1 - \hat{Y}_{xyc})^\alpha \log \hat{Y}_{xyc}, & if Y_{xyc} = 1 \\ (1 - Y_{xyc})^\beta (\hat{Y}_{xyc})^\alpha \log(1 - \hat{Y}_{xyc}), & otherwise \end{cases} \quad (3.2)$$

其中， N_{pos}^k 是正样本的数量，用于归一化损失， Y_{xyc} 是位置 (x, y) 上类别为 c 的真实热图标签， $\hat{Y}_{xyc}$ 是预测概率值。

3.2.3 区域优化模块

在 Star-Convex^[30]方法中，虽然通过关键点特征预测边界距离具有一定的效果，但由于细胞核的大小差异较大，这种方法常常不足以提供足够的上下文信息。对于较小的细胞核，预测的距离可能不准确，或者局部信息不足以准确确定细胞核的边界。因此，单纯依靠关键点信息来进行距离预测在一些情况下并不能有效解决细胞核分割问题。

为了解决这个问题，本章提出了一个区域优化模块（ROM）。该模块利用更精确的边界像素和关键点像素输出优化的掩码图像。该模块的核心思想是利用种子点（细胞核的关键点）和边界特征进行区域扩展，优化初步预测的掩码图像。ROM 的工作流程如算法 3.1 所示。

首先，ROM 从网络的预测结果中提取细胞核的关键点，关键点代表了细胞核的大致中心位置。每个关键点可以视为细胞核的种子点 q 。接着，对于每个种子点 q 通过算法计算其周围 8 个邻域点 $N(q)$ 的位置，获取细胞核可能扩展的区域。这些邻域点是潜在的细胞核边缘或扩展区域。

然后，对于每一个邻域点 $N(q)$ ，ROM 使用边界特征图来指导区域生长。具体来说，边界特征提供了细胞核边缘的可能位置，算法会根据这些信息扩展邻域点，并约束区域生长过程仅在核边界内进行。这一约束确保了细胞核的边界不被过度扩展或缩小。

最后，通过以上步骤，每个关键点都会扩展到其对应的完整细胞核区域，最终形成一个连续的细胞核掩码图像。这种优化后的掩码不仅精确描述了细胞核的轮廓，还确保了多个细胞核之间不会出现过多重叠。

综上，该模块能够精确定位细胞核中心，避免传统方法在密集细胞核区域的误判，并通过边界特征精确描述核的形状，有效解决重叠核分割问题。通过融合关键点与边界信息，ROM 显著提升了细胞核分割的准确性与鲁棒性。此外，该方法能够适应不同大小、形状及重叠程度的细胞核，增强了在复杂场景下的泛化能力，同时保证了分割掩码的连续性与准确性。

算法 3.1 区域优化模块

算法 3.1 区域优化模块

```

1:  输入: 关键点  $P = \{P_1, P_2, \dots, P_n\}$ , 边界  $C = \{C_1, C_2, \dots, C_n\}$ 
2:  输出: 重新定义掩码预测图  $M$ 
3:  初始化一张掩码图片  $M$  尺寸与边缘图一样大小并且像素值置为 0
4:  for each  $i$ , center in heat map  $p$  do:
5:       $Q = \{p_i\} \leftarrow i$ , center
6:      while not  $Q.empty()$  do
7:           $q \leftarrow Q.get()$ 
8:           $N(q) \leftarrow \text{Get neighboring points}(q)$ 
9:          for each  $n$  in  $N(q)$  do
10:             if  $n$  is within contour and  $M(n) = (0,0,0)$  then
11:                  $M(n) \leftarrow (i+1, i+1, i+1)$ 
12:                  $Q.put(n)$ 
13:             end if
14:         end for
15:     end while
16: end for
17: return  $M$ 

```

3.2.4 损失函数

三个分支组成了网络模型的输出:关键点、边缘和掩码。损失函数用 $\mathcal{L}_{total}$ 表示,其计算公式如下所示:

$$\mathcal{L}_{total} = \omega_1 \mathcal{L}_{keypoint} + \omega_2 \mathcal{L}_{edge} + \omega_3 \mathcal{L}_{mask} \quad (3.3)$$

其中, $\mathcal{L}_{keypoint}$ 、 $\mathcal{L}_{edge}$ 和 $\mathcal{L}_{mask}$ 分别表示三个分支中 mask、edge 和 keypoint 的损失。每个权重系数用 ω_i 表示。对于每个 $\mathcal{L}_{edge}$ 和 $\mathcal{L}_{mask}$, 通过将标准二进制交叉熵损失和 Dice 损失相加来计算损失, 其计算公式如下所示:

$$CE = - \sum_{(r,c)}^{(H,W)} [P_{G(r,c)} \log P_S(r,c) + (1 - P_{G(r,c)}) \log (1 - P_S(r,c))] \quad (3.4)$$

$$Dice = 1 - \sum_{(r,c)}^{(H,W)} \left(\frac{2 \times P_S(r,c) \times P_G(r,c)}{P_S^2(r,c) + P_G^2(r,c)} \right) \quad (3.5)$$

$$\mathcal{L}_{edge} = \mathcal{L}_{mask} = CE + Dice \quad (3.6)$$

其中, 图像的像素用 (r, c) 表示, $P_G(r, c)$ 表示该像素的真实值标签, $P_S(r, c)$ 表示模型预测像素为正标签的概率。对于关键点的损失, 按照公式 (3.2) 进行计算。该模

型可以学习准确地预测细胞核的位置，有助于提高定位的精度。

3.2.5 后处理模块

在网络结构改进后，由于边界分支输出的结果不够清晰，尽管通过 ROM 对边界和关键点进行了处理，形态学上仍存在不连续的边界，导致在区分每个实例时出现过分割的问题。

为了解决这一问题，本章提出了一种新的后处理实例分割方法，如算法 3.2 所示。具体地，首先从特征提取模块输出的细胞核掩码图中减去 ROM 的输出，去除不完整的边界。接着，将断开连接的区域实例化，消除冗余分区。然后，通过连通组件分析，识别并区分重叠和分离的细胞核。为了去除噪声，进一步移除面积小于 20 像素的小目标。最后，通过外向传播实例化结果，直到所有前景区域完全填充，进一步完善分割结果。该方法充分结合了 ROM 输出和细胞核掩码之间的互补信息，有效处理了小细胞核和重叠细胞核的分割问题，提升了分割结果的精度和鲁棒性。

算法 3.2 实例分割后处理

算法 3.2 实例分割后处理	
1:	输入：重新定义掩码预测图 M; Mask map N
2:	输出：Final_mask
3:	Mask_Init ← (N-M)
4:	CC ← Remove_small regions(Mask_Init)
5:	For each CC_i in CC do
6:	Kernel ← $\begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$
7:	
8:	Final_mask[CC_mask] ← Dilate_mask(CC_i)
17:	return M

3.3 实验结果与分析

3.3.1 实验设置

在 NVIDIA Tesla V100 系统上使用 PyTorch 3.7 实现了这些模型。在训练期间，保持所有数据集的原始大小，并使用数据增强技术，包括随机水平和垂直翻转，以及随机旋转。使用学习率为 0.00001 的随机梯度下降（SGD）和自适应学习率衰减策略进行优化。在关键点分支的训练中，默认下采样因子 R 为 4。关键点类型 C 的个数为 1，仅用于核分割。如果两个相同类的高斯函数重叠，取该元素的最大值。在损失函数中， ω_i 表示一组权重系数，在实验中均设为 1。对于 MoNuSeg 数据集，输入大小为 1000×1000，批处理大小为 12；对于 CMP-17 数据集，输入大小为

500×500，批大小为 8；对于 CoNSeP 数据集，输入大小为 512×512，批处理大小为 12。在 200 次训练中，每 20 次保存一次检查点。此外，在后处理阶段采用了本章特定的方法来解决核分割中的不连续性。

3.3.2 评价指标

为了评估细胞核分割算法的性能，需要使用一些标准的评价指标。这些指标通常用于量化分割结果与真实标签（ground truth）之间的差异，并帮助研究者和工程师优化算法。常见的细胞核分割评价指标包括 Dice 系数、F1 分数、AJI（Aggregated Jaccard Index）、PQ（Panoptic Quality）等。

Dice 系数是常用于评估图像分割结果与真实标签之间相似度的指标，特别适用于医学图像分割任务，如细胞核分割。该系数通过计算预测分割结果与真实标签的重叠区域来量化分割效果。其值介于 0 和 1 之间，值越接近 1 表示分割结果与真实标签的重叠程度越高，从而表明分割性能更好。Dice 系数计算公式如下：

$$Dice = \frac{2 \times TP}{2 \times TP + FP + FN} \quad (3.7)$$

其中 TP 代表真阳性，FP 代表假阳性，FN 代表假阴性，Dice 系数在细胞核分割任务中广泛应用，特别适用于评估细胞核与背景之间的分割准确性，尤其在细胞核之间重叠的情况下表现良好。

F1 分数（F1-score）是用于评价分类任务性能的重要指标，尤其在图像分割问题中，F1 分数通过像素级的分类结果来进行计算。它综合考虑了精确率（Precision）与召回率（Recall），并作为它们的加权调和平均。F1 分数的定义如下：

$$F_1 - score = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (3.8)$$

在细胞核分割问题中，传统的评价指标如 Dice 系数虽然常用，但在面对细胞核间重叠或接触的情况时，它未能全面评价模型的分割性能。尤其在细胞核图像拥挤且彼此接触时，Dice 系数可能无法充分反映模型分割的准确性。因此，为了更加全面和合理地评估细胞核分割效果，AJI（Aggregated Jaccard Index）和 PQ（Panoptic Quality）作为补充指标被提出，尤其是在复杂和密集细胞核分割任务中，这些指标提供了更细致和更准确的评价。

AJI 是一种针对细胞核分割任务提出的重要评价标准，尤其适用于评估细胞核分割中细胞核间重叠或接触的情形。AJI 基于连通域分割评价，评估每个 Ground Truth（真实标签）与其最接近的预测之间的重叠程度。具体计算公式为：

$$AJI = \frac{\sum_{i=1}^N |G_i \cap P_M^i|}{\sum_{i=1}^N |G_i \cap P_M^i| + \sum_{F \in U} |P_F|} \quad (3.9)$$

其中， G_i 表示在 N 个实际细胞核中，第 i 个细胞核对应的像素组， P_M^i 表示预测中与 G_i 具有最大交集的细胞核像素组。两者之间建立了配对关系。在公式中，每个预测细胞核像素组与实际细胞核像素组只能配对一次。 P_F 表示那些没有与任何一个 G_i 成功配对的预测细胞核像素组。

PQ 是一种综合性较强的评价指标，它结合了图像分割任务中的质量(Quality)和完整性(Completeness)两部分，适用于多目标分割任务。在细胞核分割中，PQ 可以同时衡量细胞核的识别精度和召回率。计算公式为：

$$PQ = \frac{2 \times TP}{2 \times TP + FP + FN} \times \frac{\sum_{(p,g) \in TP} IOU(p,g)}{|TP|} \quad (3.10)$$

其中， p 和 g 分别表示预测值和真实标签（Ground Truth）。PQ 指标的第一项是检测质量，它与 F1-Score 相似，用于衡量实例检测的效果。第二项是分割质量，它表示检测到的实例与其匹配的真实标签之间的接近程度。

3.3.3 对比实验

为了进一步验证所提出的 SES-Net 模型的分割性能，将其与多种先进的分割方法进行了对比，包括 U-Net、Mask R-CNN^[18]、DIST^[25]、DCAN^[23]、Micro-Net^[68]、HoVer-Net^[29]和 HARU-Net^[69]。所有模型均在相同的 MoNuSeg 数据集上训练，并使用一致的训练数据和超参数设置，以确保性能评估的公平性。图 3.3 展示了不同模型在训练过程中的损失变化图，其中横轴表示训练的迭代次数（Epoch），纵轴表示对应的损失值。

图 3.3 为不同模型在训练过程中的损失变化图。实验结果表明，损失黑色曲线表示 SES-Net 的损失值变化，可以明显看出 SES-Net 在训练过程中收敛速度优于其他模型。具体来说，SES-Net 的损失曲线呈现出更加平稳且较快速下降的趋势，在较早的训练轮次内就表现出了较低的损失值，并最终在较短的时间内接近最优解，相较于其他竞争模型，SES-Net 具备更高的训练效率。尤其是在与 U-Net、HoVer-Net 以及其他深度网络模型的比较中，SES-Net 显示了更强的训练稳定性，避免了在训练过程中的大幅度波动。这一优势反映在其恢复到低损失值的速度和训练的稳定性上，比多数模型快速接近最优解的特性提升了它的训练效率。综上所述，从损失曲线对比来看，SES-Net 在细胞核实例分割任务上凭借其独特的网络设计（多分支网络结构和区域优化模块）展现出了显著的训练效率优势。与其他模型相比，SES-Net 的性能表现突出，并且其较快的收敛速度表明了该模型在实际应用中具有

较高的实用价值，尤其适于快速、精确地进行图像分析与分割任务。




图 3.3 不同模型在训练过程中的损失变化图

接下来，在本节中对 SES-Net 方法与其他核分割技术进行了定量和定性比较，具体实验如表 3.1 与表 3.2 所示。

表 3.1 所提出方法与其他网络在 MoNuSeg、CoNSeP 数据集中的实验结果

Model	MoNuSeg			CoNSeP		
	Dice	AJI	PQ	Dice	AJI	PQ
U-Net ^[42]	0.758	0.556	0.478	0.724	0.482	0.328
Mask R-CNN ^[18]	0.760	0.548	0.509	0.740	0.474	0.460
DIST ^[25]	0.786	0.560	0.443	0.804	0.502	0.398
DCAN ^[23]	0.793	0.525	0.492	0.733	0.289	0.256
Micro-Net ^[68]	0.797	0.560	0.519	0.794	0.527	0.449
HoVer-Net ^[29]	0.826	0.618	0.597	0.853	0.571	0.547
HARU-Net ^[69]	0.838	0.656	0.642	0.856	0.554	0.518
SES-Net(Ours)	0.837	0.672	0.648	0.865	0.584	0.551

表 3.2 所提出方法与其他网络在 CMP-17 数据集中的实验结果

Model	CMP-17		
	Dice	AJI	PQ
U-Net ^[42]	0.847	0.664	0.522
Mask R-CNN ^[18]	0.850	0.684	0.530
DIST ^[25]	0.826	0.616	0.504
DCAN ^[23]	0.828	0.561	0.470
Micro-Net ^[68]	0.857	0.668	0.541

续表 3.2 所提出方法与其他网络在 CMP-17 数据集中的实验结果

Model	MoNuSeg		
	Dice	AJI	PQ
HoVer-Net ^[29]	0.869	0.705	0.697
HARU-Net ^[69]	0.875	0.708	0.689
SES-Net(Ours)	0.880	0.732	0.678

表 3.1 与表 3.2 为所提出方法与其他网络在 MoNuSeg、CoNSeP, CMP-17 数据集中的对比实验结果。实验结果表明, SES-Net 在核分割任务中取得了最高的性能。具体地, 在 MoNuSeg 数据集中, 提出的 SES-Net 实现了 Dice 为 0.837,AJI 为 0.672,PQ 为 0.648。在 CoNSeP 数据集中, SES-Net 的 Dice 为 0.865,AJI 为 0.584,PQ 为 0.551。在 CMP-17 数据集中, SES-Net 的 Dice 为 0.880,AJI 为 0.732,PQ 为 0.678。在 MoNuSeg 数据集中, HARU-Net 比 SES-Net 获得了稍高的 Dice 分数, 这主要是由于 HARU-Net 采用了复杂的网络架构和更深的网络层, 从而提高了分割精度。相比之下, SES-Net 的设计是轻量级的, 模型参数更少, 网络结构更简单。尽管 SES-Net 的模型复杂度和参数数量较低, 但它仍然能够获得与 HARU-Net 相当的 Dice 分数。此外, 与 MoNuSeg、CoNSeP 和 CMP-17 数据集上的其他方法相比, SES-Net 表现出了较好的性能。

3.3.4 可视化分析

为进一步验证模型性能, 将其在 MoNuSeg、CoNSeP 和 CMP-17 数据集上进行了详细的定性可视化分析。可视化结果包括以下内容: (a) 原始图像; (b) 代表性样本贴片; (c) 真实标注 (Ground Truth); (d) U-Net 预测结果; (e) DIST^[25] 预测结果; (f) HoVer-Net^[29] 预测结果; (g) 本章提出的 SES-Net 预测结果。分割结果按数据集排列: MoNuSeg (上)、CMP-17 (中) 和 CoNSeP (下)。具体实验如图 3.4 所示。




图 3.4 不同模型在 MoNuSeg、CoNSeP 和 CMP-17 数据集的分割结果图

图 3.4 为不同模型在 MoNuSeg、CoNSeP 和 CMP-17 数据集的分割结果图，为清晰对比不同方法的表现，图像中的不同实例以多种颜色区分，并使用红色矩形高亮特定区域，以突出 SES-Net 在分割任务中的关键优势。从可视化分割结果中可以看出，SES-Net 在核实例分割任务中稳定优于所有其他方法。特别是，红色矩形区域生动展现了 SES-Net 在分离核像素、区分背景与粘连细胞核实例方面的独特能力。相较于其他方法，SES-Net 能更准确地捕捉细胞核边界，避免过度分割或漏分割现象。这些发现不仅在定量指标上验证了 SES-Net 的优越性，同时也提供了强有力的定性证据，表明该方法在复杂组织图像的处理上具有更高的鲁棒性和准确性。

3.3.5 模型运行时间分析

为了评估不同细胞核分割方法的运行效率，将其在 MoNuSeg 数据集上测量了多种主流模型在单张图像上的平均运行时间。包括 StarDist^[21]、HoVer-Net^[29]、Keypoint-graph^[70]、CPP-Net^[26]和本章方法 SES-Net。为确保公平性，在相同硬件条件下对运行时间进行了对比分析：GPU:NVIDIA Tesla V100 16GB HBM2，输入 MoNuSeg 测试集图像调整为 512×512 像素，运行时间包括记录前向传播（即推理过程）及必要的后处理操作。具体实验如表 3.2 所示。

表 3.3 MoNuSeg 数据集上平均预测时间结果

Methods	预测时间（毫秒/每张图片）
StarDist ^[21]	70-130ms
HoVer-Net ^[29]	100-150ms
Keypoint-graph ^[70]	90-120ms
CPP-Net ^[26]	80-120ms
SES-Net(Ours)	80-130ms

表 3.3 为提出方法与其他网络在 MoNuSeg 中的平均预测时间实验结果。实验结果表明，StarDist 由于其基于点检测与形状先验的策略，整体预测速度最快，但在分割复杂形态的细胞核时可能存在精度上的局限。HoVer-Net 虽然在分割精度方面表现出色，但由于其网络结构较为复杂，且需要额外的特征映射（水平与垂直位移图）来区分相邻细胞核，因此运行时间最高（100-150 毫秒/图）。Keypoint-graph 需要在实例级别做图结构关联，预测速度明显慢于大部分卷积网络方法。CPP-Net 与 SES-Net 均通过较轻量化的网络结构和高效的后处理策略，在保证分割效果的同时保持了较快的预测速度（保持在 80-120ms 毫秒/图），在大规模病理图像分析中具有较高的实用性。

3.3.6 消融实验

为了评估 SES-Net 中每个模块的性能,使用 MoNuSeg 和 CoNSeP 数据集上进行了一系列消融实验,基线模型(Mask)取消点分支与边缘分支,只采用掩码分支进行分割,Edge 示基线模型增加边缘分支,Point 表示在基线模型增加关键点分支。需要说明的是,基线模型跳过 ROM 模块直接进入后处理,而其他方案均默认经过 ROM 模块。具体实验结果如表 3.4 所示。

表 3.4 MoNuSeg 数据集上各分支消融实验结果

Mask	Edge	Point	MoNuSeg			CoNSeP		
			F1	Dice	AJI	F1	Dice	AJI
✓			0.762	0.751	0.544	0.722	0.723	0.488
✓	✓		0.811	0.819	0.566	0.795	0.804	0.525
✓	✓	✓	0.830	0.837	0.672	0.845	0.865	0.584

表 3.4 为所提出方法在 MoNuSeg 数据集上各分支消融实验结果。实验结果表明,仅采用掩码分支的基线模型在 MoNuSeg 数据集上取得 F1 为 0.762、Dice 为 0.751 和 AJI 为 0.554 的成绩,而在 CoNSeP 数据集上分别为 0.722、0.723 和 0.488。引入边缘分支后,MoNuSeg 数据集上 Dice 指标有较大提升(由 0.751 提高至 0.819),但 AJI 指标略有波动;在 CoNSeP 数据集中,各项指标均有所改善。进一步同时引入关键点分支后,MoNuSeg 数据集上的 F1、Dice 和 AJI 分别提升至 0.830、0.837 和 0.672,同时 CoNSeP 数据集上的性能也相应提高(F1、Dice 和 AJI 分别达到 0.845、0.865 和 0.584)。研究结果表明,在 SES-Net 中引入关键点监督策略和边界监督策略有助于模型学习更有效的特征。

接下来为了验证区域优化模块(ROM)的有效性,本章对 ROM 模块进行了消融实验,采用基线网络(Baseline)取消使用 ROM 模块,输出特征图直接进入后处理,“Baseline + fusion”表示在本章的方法中直接采用点、线、面三者简单加权融合,“Baseline + ROM”表示采用本章方法。具体实验结果如表 3.5 所示。

表 3.5 MoNuSeg 数据集上 ROM 消融实验结果

Methods	MoNuSeg		
	F1	Dice	AJI
Baseline	0.798	0.768	0.560
Baseline + fusion	0.813	0.818	0.592
Baseline + ROM	0.844	0.837	0.672

表 3.5 为所提出方法在 MoNuSeg 数据集上 ROM 消融实验结果。实验结果表

明，在 Baseline 的基础上，直接采用了直接融合策略（Baseline+fusion），将边界（线）和关键点（点）信息与区域（面）信息进行简单的加权融合。Baseline + fusion 的 F1、Dice 和 AJI 分别提升了 1.5%、5%和 3.2%。由此可以看出，直接融合不同层次信息能够在一定程度上补充传统分割网络在细节捕捉上的不足，从而提升整体分割性能。

进一步地，在直接融合策略的基础上引入了 ROM，构建了 Baseline+ROM 模型。该模块旨在充分整合点、线、面三类信息，优化分支间的交互提高细胞核边界和区域一致性。实验结果表明，Baseline+ROM 在 MoNuSeg 数据集上的 F1、Dice 和 AJI 分别提升了 3.2%、1.9%和 8%。这一结果证明，ROM 模块在整合多源监督信息、减少边界混淆以及提高分割精度方面具有明显优势。

3.4 本章小结

本章提出了一种基于点线面特征融合的细胞核实例分割算法 SES-Net，旨在更精确地分割核实例。SES-Net 采用三支架构，分别学习关键点特征、边缘特征和核特征，并通过特征融合提高分割性能。为了优化分割结果，模型结合区域优化模块，通过关键点种子引导实例生成，同时利用边缘特征进行约束，进一步提升实例分割的准确性。最后，本章提出了一种更合理的后处理方法，利用不同任务的特征来细化核实例边界。在实验部分，采用 MoNuSeg 数据集进行了全面评估，包括消融实验和模型对比实验。消融实验表明，点、线、面信息的联合学习对提升分割精度具有重要作用，而 ROM 模块能够有效优化实例边界，使得分割结果更加精细。在与现有方法的对比实验中，SES-Net 在分割性能和推理速度之间取得了良好的平衡，相比 HoVer-Net 和 KeypointGraph 具有更快的推理速度，同时保持了较高的分割精度。综合来看，SES-Net 通过点、线、面特征融合提升了实例分割的精准度，并在计算效率上优于部分复杂模型。本章的研究为数字病理图像中的细胞核分割任务提供了一种高效且高精度的解决方案，为后续研究奠定了基础。

第4章 基于密集连接网络与文本提示的细胞核分割算法

4.1 引言

在目前细胞核分割任务中，许多方法通过增加路径结构提升了分割精度，但其多路径设计仍面临特征空间竞争的挑战，这可能影响模型在新数据集上的泛化能力和适应性。这也揭示了当前医学图像分割研究的一大瓶颈：大多数方法仍局限于单模态视觉信息的优化，即便在网络架构或损失函数上有所改进，面对细胞核形态复杂、背景干扰显著的病理图像，单一维度的优化策略难以全面捕捉目标区域的综合特征。此外，一些研究逐渐开始探索将自然语言处理技术引入医学图像分割，以实现文本-图像的多模态联合建模。这种跨模态学习框架在理论上能够增强模型的表征能力和泛化性能，促进医学图像信息的多层次理解。然而，在细胞核分割任务实际应用中，由于形态异质性、染色对比度变化和复杂背景，现有方法仍难以实现精准分割。因此，如何在跨模态信息融合与特征表达增强方面进一步提升模型的泛化性，仍是医学图像分割领域值得深入探索的问题。

为了解决以上问题，本章提出了一种基于密集连接网络与文本提示的细胞核分割算法。具体而言，该方法是结合文本提示的单一路径结构，通过引入 CLIP 模型提示的语义信息，为每个细胞核图像提供文本描述（如“细胞核”、“边界”、“背景”），以帮助模型理解细胞核的语义特征。在此基础上，本章在传统 U-Net 架构中引入了密集连接，以增强特征的重用能力并促进语义信息的融合，并在编码器瓶颈层使用 CFM 模块，融合了文本和图像特征。通过在编码器与解码器之间跳跃连接处结合跨模态注意力机制，计算图像和文本特征之间的相似性，动态调整图像特征的注意力权重，从而优化跳过连接。实验结果表明，所提出的方法在多个评价指标上表现优越，尤其在细胞核形态复杂或图像背景杂乱的情况下，相较于传统的多路径方法，具备更高的计算效率和更强的稳定性。

4.2 基于密集连接网络与文本提示的分割模型

为了使用单一路径提取边缘与细胞核特征，本方法将细胞核分割任务重新定义为分类与分割任务。本章提出了一种基于密集连接网络与文本提示的细胞核分割算法（CLIP-driven Refined U-Net, CRU-Net），整体架构如图 4.1 所示。CRU-Net 的整体框架包括两个主要分支：图像分支和文本分支。首先，输入的文本提示被送到文本分支，生成每个类别的 CLIP 嵌入，为图像分支注入语义信息。接下来，图

像分支从输入图像中提取多尺度视觉特征，并与文本分支生成的语义信息进行融合，实现对细胞核的精确分割。

在图像分支中，采用了密集连接的编码器-解码器结构，并在跳跃连接处引入跨模态注意力机制。这种结构使得编码器能够提取多尺度的全局语义信息，解码器则逐步恢复图像的空间分辨率。跨模态注意力机制的引入使得高分辨率的细节信息能够直接从编码器传递到解码器，有效地保持空间信息并改善梯度传播，从而提升分割精度和网络性能。为了融合图像与文本的多模态特征，本文设计了跨模态引导模块（Cross-modal Fusion Module, CFM），引导分割模型更准确地区分细胞核及其边缘区域。

在文本分支中，将病理图像划分为三类：细胞核、细胞核边缘和背景。采用预训练的 CLIP 文本编码器，将医学提示词（如“nuclei”，“edge”，“background”）转化为语义向量，为分割任务提供全局语义指导。文本编码器和图像编码器并行工作，随后通过多模态特征融合模块进行特征融合，得到丰富的语义信息实现细胞核分割。




图 4.1 CRU-Net 网络结构

4.2.1 文本分支

与相对独立的多类分割任务不同^[63-70]，细胞核与其周围环境（特别是边缘）之间的紧密关联导致了显著的特征空间竞争。这种竞争模糊了核和边缘之间的界限。它增加了模型准确区分和精确分割细胞核的难度，对整体分割性能产生负面影响。为了有效应对这一挑战，本章从 CLIP 中汲取灵感，提出了创新策略。该策略目的是引入文本信息来指导和调节图像特征的提取，从而实现高效的特征聚合和精确

分离。

在本章研究中，使用了在 ImageNet 上预训练的 CLIP 模型^[58]，其中文本编码器用于处理医学文本提示，目的是在将文本转化为可以与图像特征有效融合的向量表示。首先，将病理图像划分为三类：细胞核、细胞核边缘和背景。采用预训练的 CLIP 文本编码器，将医学提示词（如“nuclei”，“edge”，“background”）转化为语义向量，随后，将语义向量输入到自适应层，该层依次由全连接层、ReLU 激活函数和全连接层构成。由于 CLIP 的文本提示编码器被冻结，为了提高训练效率和参数性能，故自适应层可以对从文本编码器中提取的特征进行微调，从而更好地为医学图像数据集生成针对性的文本特征。

该模块的主要作用是从输入的文本描述中提取语义特征，并生成一个固定维度的文本向量表示，该向量能够捕捉文本描述中关于细胞核及其周围环境（如边界和背景）的关键信息。通过融合图像与文本信息，网络在分割过程中不仅依赖于图像的局部视觉特征，还能从文本描述中获取全局语义指导，从而提升模型对细胞核结构的理解与分割精度。借助 CLIP 在文本和像素特征之间强大的对比学习能力，除了细胞核的特征之外，细胞核之间的相似性对于细胞核分割也是至关重要的，使得该模型可以有效地指导不同特征的聚合与分离。

4.2.2 图像分支

图像分支主要包括图像特征提取模块，本章提出的特征提取模块主要基于 U-Net 架构，如图 4.2 所示。该架构由两个对称的路径组成：编码器路径称为密集下采样（向右），用于在多个尺度上捕捉语义上下文信息；解码器路径称为密集上采样（向左），用于重新组装高分辨率图像。密集连接通过增强特征重用、改善语义信息的流动减少编码器与解码器之间的语义差距。为了连接这两条路径，引入了跨模态注意力机制，与简单的跳跃连接不同，编码器特征在与解码器特征融合之前，会经过一个计算，通过计算图像特征和文本特征的相似度，为每一个编码层图像特征分配不同的加权系数，增强与文本语义相关的区域。

密集下采样路径由五个下采样层组成，旨在逐步提取输入特征中的低级表征。输入图像的分辨率为 $256 \times 256 \times 3$ ，该编码器路径的每个下采样层执行一个密集块操作，后跟一个过渡块操作，除了第五层，它不进行任何过渡操作。在这一路径中，使用了 32、64、128、256、512 的卷积核，即每一层之后特征图的数量翻倍。密集块用于重用特征并修正分辨率损失，过渡块用于获得层间过渡。

密集上采样路径由五个上采样层组成，用于逐步恢复高分辨率特征图，并最终重构分割结果。该路径对下采样过程进行逆向操作，以逐步恢复空间信息。在解码器路径中，依次应用五个上采样层，每个上采样层后均配备一个卷积层，以融合跳跃连接信息，并进一步细化特征表示。此外，每个卷积层后紧接一个密集块，以增

强特征重用能力，提高分割性能。具体而言，该路径采用尺寸分别为 512、256、128、64 和 32 的卷积核，使特征图在每一层逐步减半，同时在输出端应用 1×1 卷积，以调整最终特征图的通道数，从而匹配分割任务的要求。

如图 4.2 所示，密集块^[31]已被合并为 4 个密集连接的层（在图 4.2 中命名为 Dense_block）。在每个密集连接的层中包含批量归一化，两个卷积操作，ReLU 激活函数和 dropout 操作。为了更好地利用提取的特征，每个层都连接到所有先前的层，目的是重复使用特征并纠正分辨率损失。为了实现层转换，采用了转换块 Trans_block。该块由三个操作组成，包括批处理归一化、卷积和最大池操作。为了使级联成功，在密集下采样路径的两个层之间应用 Trans_block。




图 4.2 特征提取模块

4.2.3 跨模态融合模块

在完成文本编码器的设计与实现之后，接下来的关键任务是如何高效地将文本与图像信息结合，以实现精确的分割。在细胞核分割任务中，选择合适的文本和图像特征融合层次至关重要。该任务的目标是通过文本描述指导图像分割，而图像分割要求精确地识别和分离重叠细胞核区域。考虑到这一任务的特点，选择在网络的最深层（即瓶颈层）进行文本与图像特征的融合可能会取得较好的效果。因为瓶颈层包含了图像的全局语义信息，尽管其空间分辨率较低，但引入文本信息可以为模型提供语义上的全局推断，从而有效指导分割过程。

本章设计跨模态融合模块（CFM）来接收输入图像特征 F_{image} 和文本特征 F_{text} 进行处理，如图 4.3 所示。首先，对图像特征 F_{image} 和文本特征 F_{text} 进行归一化，并且计算它们的余弦相似度以生成类别引导特征图 F_{cg} 。余弦相似度捕捉图像特征

和文本特征之间的关系，有效地指导模型从不同的图像区域提取和聚合特征。接下来，将生成的特征图 F_{cg} 与原始图像特征连接起来，并将其输入到 3×3 卷积和通道注意机制中，以进一步处理、提取和增强不同类别的特征信息，最终输出的特征图是 F_{out} 。卷积运算捕获局部特征，而通道注意机制动态调整不同通道的权重，突出基本特征并抑制无关或冗余信息。CFM块可以表示为：

$$F_{cg} = CS \left(\frac{F_{image}}{\|F_{image}\|}, \frac{F_{text}^T}{\|F_{text}\|} \right) \quad (4.1)$$

$$F_{out} = CA \left(Conv(F_{cg}, F_{image}) \right) \quad (4.2)$$

其中 $CS(\omega)$ 表示余弦相似性， $CA(\omega)$ 表示信道关注度。




图 4.3 跨模态融合模块

4.2.4 跨模态注意力机制

在每个编码器的跳跃连接处，本章引入了跨模态注意力机制，如图 4.4 所示。首先将 CLIP 文本特征通过线性变换映射到与图像特征相同的维度，接着使用余弦相似度计算文本特征与图像特征之间的相似度，生成自适应注意力权重，最后使用

注意力权重对图像特征进行加权,从而增强与文本描述相关的区域。具体步骤如下:

首先,输入的三个文本描述(“细胞核边缘清晰”、“细胞核呈现圆形”、“细胞周围无明显干扰”)通过 CLIP 模型或其他预训练的文本编码器进行处理,生成三个文本特征向量:

$$F_{T_1} = CLIP(T_1), F_{T_2} = CLIP(T_2), F_{T_3} = CLIP(T_3) \quad (4.3)$$

其中, F_{T_1}, F_{T_2} 和 F_{T_3} 分别是三个文本描述 T_1, T_2 和 T_3 提取的文本嵌入向量, 维度为 d 。为了有效利用这些信息, 采用向量拼接的方式将三个文本向量合并为一个统一的文本表示, 以增强模型对多模态特征的理解和利用能力。

$$F_{text} = [F_{T_1}; F_{T_2}; F_{T_3}] \quad (4.4)$$

其中, F_{text} 是拼接后的文本向量, 维度为 $3d$ 。这个拼接向量综合了三个文本描述的语义信息, 并为后续图像特征的调整提供了丰富的语义指导。

接着, 在每一层的编码器输出 F_{image} 和文本特征 F_{text} 之间, 计算跨模态注意力。利用图像特征与文本特征的相似度来调整图像特征的加权系数, 通过计算相似度能够衡量图像特征与文本描述之间的匹配程度, 从而使得模型更倾向于关注那些与文本描述一致的区域。

$$sim(F_{text}, F_{image}) = \frac{F_{text} \cdot F_{image}}{\|F_{text}\| \|F_{image}\|} \quad (4.5)$$

其中, F_{image} 为图像特征, F_{text} 为文本特征, $\|F_{text}\|$ 和 $\|F_{image}\|$ 分别为图像特征和文本特征的欧几里得范数。该相似度衡量了图像和文本描述之间的匹配程度, 值越大表示两者的相关性越强。

然后, 基于相似度值, 利用 Sigmoid 激活函数将相似度映射到 $[0,1]$ 范围内, 从而生成注意力权重。

$$A_i = \text{sigmoid}(sim(F_{text}, F_{image})) \quad (4.6)$$

这一步骤将相似度值转换为加权系数, 反映了文本描述对图像特征的影响程度。注意力权重 A_i 可以看作是对每一层图像特征的加权因子, 帮助模型关注更加符合文本描述的区域。

接下来, 利用计算得到的注意力权重 A_i , 对图像特征 F_{image} 进行加权。具体地, 图像特征 F_{image} 将与注意力权重 A_i 进行逐元素相乘操作, 得到加权后的图像特征

F_{image}^{att} :

$$F_{image}^{att} = F_{image} \odot A_i \quad (4.7)$$

其中， $\odot$ 表示逐元素相乘操作。加权后的图像特征 F_{image}^{att} 在后续的解码器阶段中被传递并用于生成细胞核分割掩码。

最后，在跳跃连接层将加权后的图像特征 F_{image}^{att} 与低层的图像特征 F_{skip} 进行融合。解码器将从编码器中传递过来的融合特征进行上采样，并逐步恢复图像的空间分辨率，通过解码器的逐步恢复，最终得到分割掩码。




图 4.4 跨模态注意力机制

4.2.5 损失函数

本节采用组合损失函数，以增强细胞核、边缘和背景的分类精度，并提升像素级分割性能。该损失函数集成了多类交叉熵和 DICE 损失函数，以优化模型在分割任务中的性能。多类交叉熵损失函数处理图像中的多类分类问题，在模型中采用这种损失函数来区分细胞核、细胞核边缘和背景。多类交叉熵损失函数定义如下：

$$L_{CE} = - \sum_{c=1}^C y_c \log p_c \quad (4.8)$$

其中， C 是类别的总数， y_c 是类别 C 的真实标签， p_c 是样本在类别 C 中的预测概率。DICE 损失函数主要用于提高像素级分割精度。其定义如下：

$$L_{DICE} = 1 - \sum_{(r,c)}^{(H,W)} \left(\frac{2 \times P_S(r,c) \times P_G(r,c)}{P_S^2(r,c) + P_G^2(r,c)} \right) \quad (4.9)$$

采用多类交叉熵损失函数和具有比例权重的 DICE 损失函数结合起来,以优化模型在分割任务中的性能。组合损失函数的公式如下:

$$Loss = \alpha L_{CE} + \beta L_{DICE} \quad (4.10)$$

其中, α 和 β 分别是交叉熵和 DICE 损失的权重参数, 设置为 0.6 和 0.4。这种加权确保模型在分割任务中实现高精度。

4.3 实验结果与分析

4.3.1 实验设置

在 NVIDIA Tesla V100 系统上使用 PyTorch 3.7 实现了这些模型并使用 ImageNet 上预训练的权重初始化模型参数。在训练过程中采用了各种数据增强技术, 包括弹性变换、缩放、移位、旋转和翻转。在整个训练过程中, 使用 Adam 优化器, 批量大小为 8, 权重衰减为 1×10^{-4} , 以优化反向传播模型。训练集用于模型的训练与参数优化, 训练过程中根据验证结果动态调整学习率, 并判断是否提前终止训练。测试集则用于评估模型的分割性能与泛化能力。对于不同数据集, 统一进行染色标准化预处理后分别开展实验, 并统计各自的分割结果。

4.3.2 对比实验

为了验证提出的 CRU-Net 模型的分割任务中的表现, 将其与 U-Net、HoVer-Net、Micro-Net 和 Universal-Model 等先进方法在 MoNuSeg 数据集上进行对比试验, 并且使用一致的训练数据和超参数设置确保各个模型在性能评估中的公平性。图 4.5 展示了不同模型在训练过程中损失值的变化趋势, 横轴代表训练的迭代次数 (Epoch), 纵轴表示训练中的损失值。




图 4.5 不同模型在训练集上的损失变化图

实验结果表明,不同模型在训练过程中的收敛速度和稳定性存在明显差异。整体上,各模型的损失值在训练初期快速下降,随后逐步趋于平稳。其中,CRU-Net 的收敛速度与 Universal-Model 相近,但在后期损失曲线更加平滑,表明模型的训练过程更加稳定,泛化能力更强。而 HoVer-Net 在前 50 轮内下降较快,但在训练后期损失曲线波动较大,可能是由于其多分支结构对边界信息的依赖度较高,导致学习过程中的不稳定性。此外,U-Net 和 Micro-Net 的损失曲线整体下降较慢,并在训练后期出现较大波动,表明其在复杂背景下的学习能力有限。Universal-Model 由于采用了 CLIP 预训练嵌入作为语义指导,其损失在前期下降速度较快,且最终稳定在较低水平。然而,与 Universal-Model 相比,CRU-Net 在引入 CLIP 提示的同时,采用了密集连接的编码器-解码器结构,并结合自适应跳跃连接,有效地增强了多尺度信息的利用,进而在损失收敛性上表现出更好的稳定性。

接下来,将提出的 CRU-Net 与几个基线模型进行了比较,包括(1)DIST^[25], (2)DCAN^[23], (3)Micro-Net^[68], (4)HoVer-Net^[29], (5)Triple U-Net^[27], (6)SES-Net, (7)Universal-Model^[71],具体实验结果如表 4.1 所示。

表 4.1 MoNuSeg 和 CoNSeP 数据集上的对比实验结果

Model	MoNuSeg			CoNSeP		
	Dice	AJI	PQ	Dice	AJI	PQ
DIST ^[25]	0.786	0.560	0.443	0.804	0.502	0.398
DCAN ^[23]	0.793	0.525	0.492	0.733	0.289	0.256
Micro-Net ^[68]	0.797	0.560	0.519	0.794	0.527	0.449
HoVer-Net ^[29]	0.826	0.618	0.597	0.853	0.571	0.547
Triple U-Net ^[27]	0.837	0.621	0.601	0.843	0.579	0.562
SES-Net(Ous)	0.837	0.672	0.648	0.865	0.584	0.551
Universal-Model ^[71]	0.810	0.621	0.574	0.850	0.565	0.546
CRU-Net(Ous)	0.840	0.650	0.625	0.858	0.595	0.570

表 4.1 展示了 CRU-Net 与基线模型在 MoNuSeg 和 CoNSeP 数据集上的对比实验结果,在 MoNuSeg 数据集上,HoVer-Net 依靠水平与垂直偏移预测策略,Dice 值达到 0.826,并在目标实例分割方面表现出一定优势。SES-Net 与 Triple U-Net 都通过三支结构进行多尺度特征提取,有效提升了分割精度,Dice 均达到 0.837,并且在分割区域的完整性上表现出色。然而,这三个方法多路径依赖结构与额外的后处理步骤,影响了局部区域的独立性。Universal-Model 结合 CLIP 进行文本引导分割,虽然在语义信息利用方面有所增强,但由于文本-图像匹配的不确定性,其 Dice 仅为 0.810,略低于 SES-Net 和 HoVer-Net。相比之下,CRU-Net 采用密集连接结构提升特征复用能力,并结合跨模态注意力优化图像与文本特征的融合,最终在 MoNuSeg 数据集上取得了最优结果,Dice 达到 0.840,较 SES-Net 和 Universal-

Model 分别提升 0.3%和 3.0%。

在 CoNSeP 数据集上, HoVer-Net、SES-Net 和 Universal-Model 的分割性能存在一定差异。HoVer-Net 在 Dice 指标上达到 0.853, SES-Net 进一步提升至 0.865, 而 Universal-Model 则为 0.850, 表明其在多样化组织背景下具备一定适应能力。然而, Universal-Model 的文本引导分割在该数据集上的效果未能充分发挥, 可能受限于文本-图像匹配的不确定性。相比之下, CRU-Net 在该数据集上取得了更为均衡的表现, Dice、AJI 和 PQ 分别达到 0.875、0.595 和 0.570。该结果表明, CRU-Net 通过密集连接结构提升了特征学习能力, 并结合跨模态注意力机制增强了不同模态特征的交互, 从而在复杂的组织背景下依然能够保持稳定的分割性能。

4.3.3 可视化分析

为了直观展示该模型在细胞核分割任务中的优势, 本节选取了 HoVer-Net、Universal-Model 和 CRU-Net 在 MoNuSeg 和 CoNSeP 数据集上的分割结果进行定性可视化对比分析。其中, (a) 为输入图像, (b) 为真实值 (Ground Truth), (c) 为 CRU-Net 结果, (d) 为 HoVer-Net 结果, (e) 为 Universal-Model 结果。具体实验结果如图 4.6 所示。




图 4.6 不同模型在 MoNuSeg 和 CoNSeP 数据集分割结果图

从图中可以观察到, HoVer-Net、Universal-Model 和 CRU-Net 三种方法在简单

图像中的表现均良好，然而一旦涉及到更加复杂的情况（如细胞粘连）时，分割结果仍然存在一定差异。在 HoVer-Net（图 d）分割结果中，它在边界区分度方面仍显不足，尤其是在密集核区域出现核粘连细胞核分割困难。Universal-Model（图 e）作为医学大模型，通过大规模预训练提升了其在不同数据集上的泛化能力。然而，由于其主要针对多任务医学影像解析进行优化，导致在细胞核边界精细刻画方面不如专门针对细胞核分割任务设计的模型，在复杂背景细胞核处理中仍然存在一定的边界模糊和区域误分割现象。CRU-Net（图 c）采用单路径结构进行高效特征聚合，结合解码阶段的 CLIP 语义引导，其细胞核边界更加清晰，形态完整，细节刻画精准，特别是在真值图分割不清楚的情况下，展现出更强的适应能力和泛化能力。总的来说，CRU-Net 既弥补了 HoVer-Net 对密集细胞核区域的不足，也克服了 Universal-Model 在细粒度分割上的局限性，最终在细胞核分割任务中展现出更高的准确性与泛化能力，为医学图像分析提供了一种高效、稳健的解决方案。

4.3.4 泛化性实验

医学深度学习模型的核心目标之一是具备良好的泛化能力，即在未见过的、不同分布的数据集上依然保持优异的性能，而非仅在特定数据集上表现良好但存在过拟合风险。为了评估所提出模型的泛化能力，本节设计了一系列实验，旨在验证模型在未知数据集上的表现。实验设计如下，在 MoNuSeg 训练集上训练模型，并在 CoNSeP 测试集上进行评估；在 CoNSeP 训练集上训练模型，并在 MoNuSeg 测试集上进行评估。具体实验结果如表 4.2 和表 4.3 所示。

表 4.2 MoNuSeg 数据集上的泛化实验结果

Model	Train→Test	PQ	Dice	AJI
HoVer-Net ^[29]	MoNuSeg→CoNSeP	0.547	0.795	0.572
SES-Net(Ous)		0.559	0.803	0.598
Universal-Model ^[71]		0.518	0.810	0.587
CRU-Net(Ous)		0.574	0.831	0.615

表 4.3 CoNSeP 数据集上的泛化实验结果

Model	Train→Test	PQ	Dice	AJI
HoVer-Net ^[29]	CoNSeP→MoNuSeg	0.432	0.765	0.465
SES-Net(Ous)		0.456	0.779	0.580
Universal-Model ^[71]		0.434	0.781	0.499
CRU-Net(Ous)		0.552	0.805	0.590

表 4.2 和表 4.3 展示了不同模型在跨数据集测试中的泛化性能。实验结果表明,与 HoVer-Net、SES-Net 和 Universal-Model 模型相比,本章模型在 MoNuSeg→CoNSeP 上,Dice、AJI 和 PQ 分别提高了 2.7%、3.6%和 4.3%。在 CoNSeP→MoNuSeg 上 Dice、AJI 和 PQ 分别提高了 12%、4%和 12.5%。

HoVer-Net 在两个实验场景下的 AJI 指标均低于 0.58,表明其分割结果受数据分布变化的影响较大。SES-Net 在 Dice 指标上相比同一个数据集测试时下降较多,说明其多路径结构可能对数据分布漂移较为敏感,难以保持稳定的分割性能。Universal-Model 在 Dice 上表现较优,但 PQ 指标较低,可能是由于 CLIP 语义匹配存在一定误差,使其在形态复杂的细胞核分割任务中存在局限。相比之下,CRU-Net 在 Dice 和 AJI 指标上均取得最高值,说明其单路径结构能够更好地适应不同数据集的变化,具备更强的泛化能力。

模型的泛化能力受多个因素影响。多路径结构由于参数复杂,可能会学习到特定数据集的噪声模式,导致模型在未知数据集上的表现不稳定。而 CRU-Net 通过单路径设计,有效减少了过拟合风险,使模型更专注于关键特征的学习。此外,结合文本描述信息可以在泛化性上带来额外优势。CLIP 通过学习图像与文本的深层语义关联,使模型在面对不同数据分布时,能够借助语言信息提高关键区域的识别能力,从而增强分割的稳定性。实验结果进一步验证了 CRU-Net 结合语言引导的能力,使其在跨数据集任务中展现出更优的泛化表现。

4.3.5 消融实验

为全面评估本章提出的 CRU-Net 中各模块对细胞核实例分割性能的贡献,本节设计了系统性消融实验,采用 Dice 系数、AJI 和 PQ 作为评价指标。实验在 MoNuSeg 数据集上进行,涵盖以下配置:(1) CRU-Net (完整模型)(2) CRU-Net w/o Dense: 移除密集连接,恢复为普通卷积类似 U-Net 结构。(3) CRU-Net w/o CFM: 禁用跨模态引导模块,CRIS^[60]的方法添加到编码器瓶颈处代替 CFM 模块。(4) CRU-Net w/o CLIP: 移除 CLIP 语义分支,编码器瓶颈处取消 CFM 模块,仅使用图像分支进行分割。(5) CRU-Net w/o Skip: 取消跨模态跳过连接采用简单跳过连接,保留编码器-解码器主干。(6) CRU-Net w/r ResNet: 将密集连接替换为 ResNet 的残差连接。在这些实验中,CRNS-Net 的所有变体都与完整模型参数配置保持一致。具体实验结果如表 4.4 所示。

表 4.4 MoNuSeg 数据集上的消融实验结果

模型配置	Dice	AJI	PQ
CRU-Net (完整模型)	0.840±0.02	0.650±0.03	0.625±0.02
CRU-Net w/o Dense	0.809±0.03	0.613±0.04	0.587±0.03

续表 4.4 MoNuSeg 数据集上的消融实验结果

模型配置	Dice	AJI	PQ
CRU-Net w/o CFM	0.802±0.03	0.595±0.04	0.563±0.03
CRU-Net w/o CLIP	0.781±0.04	0.554±0.05	0.521±0.04
CRU-Net w/o Skip	0.763±0.04	0.532±0.05	0.498±0.04
CRU-Net w/r ResNet	0.828±0.02	0.631±0.03	0.602±0.02

取消密集连接后, Dice 从 0.840 降至 0.815, AJI 从 0.650 降至 0.613。密集连接通过特征复用显著提升了模型对细胞核边缘细节的捕获能力,尤其在小型细胞核(直径<15 像素)的分割上表现突出,小目标 Dice 提升 4.2%。移除 CLIP 分支后, AJI 从 0.650 降至 0.554, PQ 从 0.625 降至 0.521。CLIP 语义信息显著增强了模型对细胞核类别的判别能力,尤其在染色不均匀或背景复杂的样本上表现显著,低对比度样本的 PQ 提升 22.3%。将跨模态跳过连接替换为普通跳过连接, AJI 从 0.650 降至 0.532, PQ 从 0.625 降至 0.498。跨模态跳过连接通过传递高分辨率细节信息,有效缓解了细胞核形状失真问题,尤其在细胞核形态不规则(长宽比>2.5)的样本中, PQ 提升 25.6%。使用 ResNet 残差连接时, Dice 为 0.828, PQ 为 0.602,较完整模型略有下降。密集连接在细胞核边缘区域(边界宽度<3 像素)的 PQ 表现更优(62.5%vs.58.7%),验证了其在特征复用上的优势。

CFM 有效性: 由于细胞核图像的不均匀染色可能导致 CLIP 错误地将非细胞核区域分类为细胞核,从而影响分割性能。为此,本章基于 Universal-Model 引入了 CFM 模块,该模块在保留原始信道信息的同时,结合 CLIP 进行类引导,以提升特征提取的准确性。CLIP 能够将图像和文本映射到相同的向量空间,从而使模型学习图像与其文本描述之间的相似性;然而,单纯加入 CLIP 会使未使用 CFM 模块的模型 PQ 从 0.625 降至 0.563, AJI 从 0.650 降至 0.595,反映出其在特征区分上的局限性。引入 CFM 后,模型实现了更优的特征聚类与分离效果,类似于 CRIS^[60]通过计算文本与像素特征间余弦相似度来提高分割性能,CRU-Net 在此基础上进一步结合原始信道信息进行信道关注计算,确保关键信息不被丢失。最终,CFM 模块通过优化文本-图像特征对齐,显著改善了细胞核粘连区域的分割效果,有效减少误分类。

密集连接有效性: 细胞核图像的复杂形态和边缘模糊问题可能导致传统卷积网络难以准确捕捉细胞核的细节特征,从而影响分割性能。通过引入了密集连接(Dense Connection)来解决这一问题。密集连接通过层级特征复用机制,将浅层的高分辨率细节信息与深层的语义信息相结合,显著增强了模型对细胞核边缘和小目标的特征提取能力。这种方法不仅提高了模型对细胞核形态的识别精度,还有效减少了边缘模糊区域的误分割。经过这一改进,模型在分割准确率和鲁棒性上均

取得了显著提升。

4.4 本章小结

本章提出了一个基于密集连接网络与文本提示的细胞核分割算法(CRU-Net)。该模型在 U-Net 的基础上引入了密集连接结构,通过层级特征复用机制显著改善了细胞核边缘区域和小目标的分割效果。此外,跨模态跳过连接的引入进一步优化了高分辨率细节信息的传递,提升了模型对复杂形态细胞核的分割能力。在编码器瓶颈处,设计了跨模态融合模块来融合文本与图像信息,实现了跨模态特征对齐,从而提升了模型对细胞核类别的判别能力。通过引入 CLIP 模型,CRU-Net 能够在复杂的医学图像中有效地提取细胞核边界,并提高分割精度。在 MoNuSeg 和 CoNSeP 数据集上的实验结果表明,所提出的单一路径模型在分割性能上优于 HoVer-Net、Micro-Net 和 Universal-Model 等经典模型,并且相比多路径模型,显著缓解了特征竞争问题,展现出更强的泛化能力。

第 5 章 总结与展望

5.1 结论

细胞核分割是病理诊断中的关键步骤，直接影响疾病检测、病变程度判断及治疗方案选择。细胞核的形态、大小和染色特征对癌症预测和复发风险评估具有重要意义。然而，细胞核分割任务复杂且繁琐，需要大量精力和领域知识。随着深度学习和机器视觉技术的发展，病理学领域通过数字化转型，尽管数字化病理图像能够克服传统方法中的一些困难，但也带来了新的挑战，尤其是图像质量波动、细胞核重叠以及背景干扰等因素，给细胞核分割任务带来了显著困难。

首先，针对病理图像中细胞核相互重叠、边界模糊的问题，本文提出了一种新颖的基于点线面特征融合的细胞核实例分割算法（SES-Net）。首先，设计了三支结构，分别聚焦于细胞核的关键点、边缘和掩码区域特征，能够有效地捕捉细胞核的多维信息。接下来，设计了区域优化模块（ROM），通过整合关键点和边缘特征，优化分割掩码，进而提高分割精度。最后，设计了一种将 ROM 输出与细胞核掩码图像相结合的后处理方法，以产生最终的实例分割结果。实验表明，该方法在 MoNuSeg、CoNSeP 和 CPM-17 数据集中 Dice 系数分别达到了 0.837、0.865 和 0.880。在保持较高分割精度的同时，也提高了推理速度，展示了其在计算效率和分割性能之间的平衡。消融实验表明，点、线、面信息的联合学习对提升分割精度至关重要。该方法为细胞核实例分割任务提供了新的解决方案，展现了良好的鲁棒性和精度，未来有望在更多医学图像分割任务中取得突破。

其次，针对传统多路径结构在细胞核分割中存在的特征竞争和泛化能力不足的问题。本文提出了一种基于密集连接网络与文本提示的细胞核分割算法（CRU-Net）。该方法采用单一路径结构，通过引入 CLIP 模型的语义信息，为每个细胞核图像提供文本描述，从而为模型注入细胞核的语义先验知识。该模型在 U-Net 架构的基础上，设计了密集连接结构，并通过密集的下采样和上采样路径优化了细胞核边缘区域和小目标的分割效果。此外，设计跨模态跳跃连接，使得图像和文本特征能够动态交互，通过计算图像和文本之间的相似性，优化特征的注意力分配。在编码器瓶颈处设计 CFM 模块，通过跨模态特征融合实现了文本和图像特征的对齐。实验结果表明，CRU-Net 在 MoNuSeg 和 CoNSeP 数据集上的 Dice、AJI 和 PQ 指标均有显著提升，尤其是在跨数据集验证中，最大提升分别为 12%、4% 和 12.5%。与传统的多路径模型相比，显著提高了模型的分割精度和泛化能力。

5.2 未来展望

计算病理学作为一项新兴的交叉学科，结合了医学、计算机科学与人工智能等多个领域，逐渐成为推动医疗技术发展的重要方向。尽管当前已经取得了一定的研究成果，但在细胞核分割和其他病理图像分析任务中，仍然存在许多挑战需要解决。

（1）本文所采用的 CLIP 模型主要基于全局文本描述（如“细胞核”“边缘”“背景”），但在未来的细胞核分割任务中，可进一步探索更细粒度的文本控制策略。例如，引入层次化文本信息，通过不同语义层次的提示（如“边缘清晰的细胞核”或“密集分布的细胞核”）引导模型学习更加丰富的特征；同时，也可结合 GPT 等大语言模型实现动态文本生成，提升文本描述的多样性与模型的泛化能力。

（2）虽然本文在细胞核分割任务中取得了不错的效果，但深度学习模型的“黑箱”问题依然存在，尤其是在临床应用中，医生需要理解模型的决策过程和依据。因此，提高模型的可解释性是未来研究的重要方向。通过设计更加透明的模型结构或可视化技术，帮助医生理解模型的预测结果，并增强其对模型的信任度，将是计算病理学领域的重要课题。

随着人工智能技术的不断发展和计算病理学的不断深入，未来将在模型精度、可解释性、泛化能力以及数据融合等方面取得更大的突破。这些技术的进步将为精准医疗和个性化治疗提供更加有力的支持，推动全球医疗健康水平的提升。

参考文献

- [1] Siegel R L, Miller K D, Fuchs H E, et al. Cancer statistics, 2021[J]. CA: a cancer journal for clinicians, 2021, 71(1): 7-33.
- [2] Xia C, Dong X, Li H, et al. Cancer statistics in China and United States, 2022: profiles, trends, and determinants[J]. Chinese medical journal, 2022, 135(05): 584-590.
- [3] 滕伊洋,孟娜,侯敏博,等.数字组织图像分析和人工智能在毒性病理学中的应用进展[J].药物评价研究,2025,48(04):1050-1057.
- [4] 曾军英,尹永宏,麦智鹏,等.用于病理学全视野图像分类的双流多实例学习模型[J].机电工程技术,2025,54(06):58-63.
- [5] Hayakawa T, Prasath V B S, Kawanaka H, et al. Computational nuclei segmentation methods in digital pathology: a survey[J]. Archives of Computational Methods in Engineering, 2021, 28: 1-13.
- [6] 焦一平,王向学,徐军. 计算病理学应用研究进展与挑战[J]. 协和医学杂志, 2022, 13(4): 535-541.
- [7] 韩思奇,王蕾. 图像分割的阈值法综述[J]. 系统工程与电子技术, 2002, 24(6): 91-94.
- [8] Lu C, Mahmood M, Jha N, et al. A robust automatic nuclei segmentation technique for quantitative histopathological image analysis[J]. Analytical and Quantitative Cytology and Histology, 2012, 34: 296-308.
- [9] Wienert S, Heim D, Saeger K, et al. Detection and segmentation of cell nuclei in virtual microscopy images: a minimum-model approach[J]. Scientific reports, 2012, 2(1): 503.
- [10] Zhou X, Li Y, Shen L. A novel adaptive local thresholding approach for segmentation of HEP-2 cell images[C]//2016 IEEE International Conference on Signal and Image Processing (ICSIP). IEEE, 2016: 174-178.
- [11] Vincent L, Soille P. Watersheds in digital spaces: an efficient algorithm based on immersion simulations[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 1991, 13(06): 583-598.
- [12] ZHOU X, LI F, YAN J, et al. A novel cell segmentation method and cell phase identification using Markov model [J]. IEEE Transactions on Information Technology in Biomedicine, 2008, 13(2): 152-157.

- [13] Buggenthin F, Marr C, Schwarzfischer M, et al. An automatic method for robust and fast cell detection in bright field images from high-throughput microscopy[J]. BMC bioinformatics, 2013, 14: 1-12.
- [14] Jiang H Y, Si Y, Luo X. Medical image segmentation based on improved Ostu algorithm and regional growth algorithm[J]. Journal of Northeastern University (Natural Science), 2006, 27(4): 398.
- [15] 姜慧研, 司岳鹏, 雒兴刚. 基于改进的大津方法与区域生长的医学图像分割[J]. 东北大学学报 (自然科学版), 2006, 27(4): 398.
- [16] 张立保. 基于区域增长的遥感影像视觉显著目标快速检测[J]. Chinese Journal of Lasers, 2012, 39(11): 1114001-1.
- [17] 肖明尧, 李雄飞, 张小利, 等. 基于多尺度的区域生长的图像分割算法[J]. 吉林大学学报 (工学版), 2017, 47(5): 1591-1597.
- [18] Xu B, Wang W, Falzon G, et al. Automated cattle counting using Mask R-CNN in quadcopter vision system[J]. Computers and Electronics in Agriculture, 2020, 171: 105300.
- [19] Yao K, Huang K, Sun J, et al. Pointnu-net: Keypoint-assisted convolutional neural network for simultaneous multi-tissue histology nuclei segmentation and classification[J]. IEEE Transactions on Emerging Topics in Computational Intelligence, 2023, 8(1): 802-813.
- [20] Vu Q D, Graham S, Kurc T, et al. Methods for segmentation and classification of digital microscopy tissue images[J]. Frontiers in bioengineering and biotechnology, 2019, 7: 53.
- [21] Stevens M, Nanou A, Terstappen L W M M, et al. StarDist image segmentation improves circulating tumor cell detection[J]. Cancers, 2022, 14(12): 2916.
- [22] Zhou Y, Onder O F, Dou Q, et al. Cia-net: Robust nuclei instance segmentation with contour-aware information aggregation[C]//Information Processing in Medical Imaging: 26th International Conference, IPMI 2019, Hong Kong, China, June 2–7, 2019, Proceedings 26. Springer International Publishing, 2019: 682-693.
- [23] Chen H, Qi X, Yu L, et al. DCAN: Deep contour-aware networks for object instance segmentation from histology images[J]. Medical image analysis, 2017, 36: 135-146.
- [24] Oda H, Roth H R, Chiba K, et al. BESNet: boundary-enhanced segmentation of cells in histopathological images[C]//Medical Image Computing and Computer Assisted Intervention–MICCAI 2018: 21st International Conference, Granada, Spain, September 16-20, 2018, Proceedings, Part II 11. Springer International Publishing, 2018: 228-236.

- [25] Naylor P, Laé M, Reyat F, et al. Segmentation of nuclei in histopathology images by deep regression of the distance map[J]. IEEE transactions on medical imaging, 2018, 38(2): 448-459.
- [26] Chen S, Ding C, Liu M, et al. CPP-net: Context-aware polygon proposal network for nucleus segmentation[J]. IEEE Transactions on Image Processing, 2023, 32: 980-994.
- [27] Zhao B, Chen X, Li Z, et al. Triple U-net: Hematoxylin-aware nuclei segmentation with progressive dense feature aggregation[J]. Medical Image Analysis, 2020, 65: 101786.
- [28] He H, Huang Z, Ding Y, et al. Cdnet: Centripetal direction network for nuclear instance segmentation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 4026-4035.
- [29] Graham S, Vu Q D, Raza S E A, et al. Hover-net: Simultaneous segmentation and classification of nuclei in multi-tissue histology images[J]. Medical image analysis, 2019, 58: 101563.
- [30] Schmidt U, Weigert M, Broaddus C, et al. Cell detection with star-convex polygons[C]//Medical image computing and computer assisted intervention—MICCAI 2018: 21st international conference, Granada, Spain, September 16-20, 2018, proceedings, part II 11. Springer International Publishing, 2018: 265-273.
- [31] Wang C, Zhao Z, Ren Q, et al. Dense U-net based on patch-based learning for retinal vessel segmentation[J]. Entropy, 2019, 21(2): 168.
- [32] Cao H, Wang Y, Chen J, et al. Swin-unet: Unet-like pure transformer for medical image segmentation[C]//European conference on computer vision. Cham: Springer Nature Switzerland, 2022: 205-218.
- [33] Hörst F, Rempe M, Heine L, et al. Cellvit: Vision transformers for precise cell segmentation and classification[J]. Medical Image Analysis, 2024, 94: 103143.
- [34] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [35] Hounsfield G N. Computerized transverse axial scanning (tomography): Part 1. Description of system[J]. The British journal of radiology, 1973, 46(552): 1016-1022.
- [36] Szabo T L. Diagnostic ultrasound imaging: inside out[M]. Academic press, 2013.
- [37] Lauterbur P C. Image formation by induced local interactions: examples employing nuclear magnetic resonance[J]. nature, 1973, 242(5394): 190-191.

- [38] 李真真,宋宇.从组织切片到精准诊断:病理技术的革新之路[J].健康必读,2024,(29):31-32.
- [39] 张尊豪.常规病理组织切片及诊断要点[N].医药养生保健报,2024-09-23(008).
- [40] Patel A, Balis U G J, Cheng J, et al. Contemporary whole slide imaging devices and their applications within the modern pathology department: a selected hardware review[J]. Journal of Pathology Informatics, 2021, 12(1): 50.
- [41] Basu A, Senapati P, Deb M, et al. A survey on recent trends in deep learning for nucleus segmentation from histopathology images[J]. Evolving Systems, 2024, 15(1): 203-248.
- [42] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical image computing and computer-assisted intervention—MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18. Springer international publishing, 2015: 234-241.
- [43] Aloysius N, Geetha M. A review on deep convolutional neural networks[C]//2017 international conference on communication and signal processing (ICCSP). IEEE, 2017: 0588-0592.
- [44] Nirthika R, Manivannan S, Ramanan A, et al. Pooling in convolutional neural networks for medical image analysis: a survey and an empirical study[J]. Neural Computing and Applications, 2022, 34(7): 5321-5347.
- [45] Sun M, Song Z, Jiang X, et al. Learning pooling for convolutional neural network[J]. Neurocomputing, 2017, 224: 96-104.
- [46] Bishop C M, Nasrabadi N M. Pattern recognition and machine learning[M]. New York: springer, 2006.
- [47] Clarke E L, Treanor D. Colour in digital pathology: a review[J]. Histopathology, 2017, 70(2): 153-163.
- [48] Albawi S, Mohammed T A, Al-Zawi S. Understanding of a convolutional neural network[C]//2017 international conference on engineering and technology (ICET). Ieee, 2017: 1-6.
- [49] Oktay O, Schlemper J, Folgoc L L, et al. Attention u-net: Learning where to look for the pancreas[J]. arXiv preprint arXiv:1804.03999, 2018.
- [50] Long F. Microscopy cell nuclei segmentation with enhanced U-Net[J]. BMC bioinformatics, 2020, 21(1): 8.
- [51] Kumar N, Verma R, Sharma S, et al. A dataset and a technique for generalized nuclear segmentation for computational pathology[J]. IEEE transactions on medical

- p imaging, 2017, 36(7): 1550-1560.
-
- [52] Caruana R. Multitask learning[J]. Machine learning, 1997, 28: 41-75.
- [53] Lin Y, Wang Z, Zhang D, et al. BoNuS: boundary mining for nuclei segmentation with partial point labels[J]. IEEE Transactions on Medical Imaging, 2024, 43(6): 2137-2147.
- [54] Su R, Zhang D, Liu J, et al. MSU-Net: Multi-scale U-Net for 2D medical image segmentation[J]. Frontiers in Genetics, 2021, 12: 639930.
- [55] Zhao X, Li H, Shen X, et al. A modulation module for multi-task learning with applications in image retrieval[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 401-416.
- [56] Han C, Yao H, Zhao B, et al. Meta multi-task nuclei segmentation with fewer training samples[J]. Medical Image Analysis, 2022, 80: 102481.
- [57] Jiang H, Zhang R, Zhou Y, et al. Donet: Deep de-overlapping network for cytology instance segmentation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 15641-15650.
- [58] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//International conference on machine learning. PmLR, 2021: 8748-8763.
- [59] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [60] Wang Z, Lu Y, Li Q, et al. Cris: Clip-driven referring image segmentation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 11686-11695.
- [61] Wang Z, Wu Z, Agarwal D, et al. Medclip: Contrastive learning from unpaired medical images and text[C]//Proceedings of the Conference on Empirical Methods in Natural Language Processing. Conference on Empirical Methods in Natural Language Processing. 2022, 2022: 3876.
- [62] Rao Y, Zhao W, Chen G, et al. Denseclip: Language-guided dense prediction with context-aware prompting[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 18082-18091.
- [63] Ye Y, Xie Y, Zhang J, et al. Uniseg: A prompt-driven universal segmentation model as well as a strong representation learner[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Cham: Springer Nature Switzerland, 2023: 508-518.
- [64] He K, Zhang X, Ren S, et al. Deep residual learning for image

- recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [65] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [66] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2980-2988.
- [67] Law H, Deng J. Cornernet: Detecting objects as paired keypoints[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 734-750.
- [68] Raza S E A, Cheung L, Shaban M, et al. Micro-Net: A unified model for segmentation of various objects in microscopy images[J]. Medical image analysis, 2019, 52: 160-173.
- [69] Chen J, Huang Q, Chen Y, et al. Enhancing nucleus segmentation with haru-net: a hybrid attention based residual u-blocks network[J]. arXiv preprint arXiv:2308.03382, 2023.
- [70] Zhang S, Zhao W, Guan Z, et al. Keypoint-graph-driven learning framework for object pose estimation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 1065-1073.
- [71] Liu J, Zhang Y, Chen J N, et al. Clip-driven universal model for organ segmentation and tumor detection[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2023: 21152-21164.