

基于 SAM 与 Mamba 的病理图像细胞核实例分割与 分类研究

学 生：苏晨研

目 录

第一章 研究背景与意义	1
1.1 数字病理学的临床价值	1
1.2 细胞核分析的两个核心任务	1
1.3 人工分析的局限性与自动化的必要性	2
第二章 研究现状	3
2.1 经典方法：基于能量函数的分水岭算法	3
2.2 深度学习方法的兴起	3
2.2.1 基于轮廓预测的方法	3
2.2.2 HoverNet：基于距离图的里程碑方法	3
2.2.3 基于 Transformer 的方法	4
2.2.4 基于 SAM 的适配方法	4
2.2.5 基于 Mamba 的方法	5
2.3 现有方法的共同局限	5
第三章 研究问题	7
第四章 研究方案	8
4.1 总体框架	8
4.2 各模块设计动机	8
4.2.1 为什么用 SAM Encoder	8
4.2.2 为什么用 Mamba 融合模块	9
4.2.3 为什么保留 HoverNet 的解码器	9
4.3 与现有方法的差异对比	10
第五章 实验设计	11
5.1 数据集	11
5.2 评估指标	11

5.3 对比方法	12
5.4 消融实验	12
参考文献	13

第一章 研究背景与意义

第一节 数字病理学的临床价值

癌症是全球范围内死亡率最高的疾病之一。在临床诊断中，病理切片分析是确诊癌症的“金标准”——医生通过对组织切片在显微镜下的观察，判断细胞的形态、分布和类型，从而做出诊断。随着数字扫描技术的发展，玻璃切片已经被数字化为高分辨率的全幻灯片图像（Whole Slide Image, WSI），分辨率往往高达数万 × 数万像素。这使得计算机辅助的自动分析成为可能，也催生了数字病理学这一新兴领域。

数字病理学的核心任务之一是对组织切片中的细胞核进行自动分析。细胞核的形态、大小、密度和类型分布，是判断肿瘤恶性程度、预测患者预后、指导治疗方案的重要依据。例如，肿瘤浸润淋巴细胞（Tumor Infiltrating Lymphocytes, TILs）的密度与癌症患者的生存率显著相关；核的异型性（大小不规则、染色质分布异常）是恶性肿瘤的典型特征之一。因此，精确的细胞核自动分析具有重要的临床应用价值。

第二节 细胞核分析的两个核心任务

细胞核的自动计算机分析主要包含两个子任务：

实例分割 (Instance Segmentation)：在图像中识别出每一个独立的细胞核，并给出其精确的像素级轮廓。这与语义分割不同——语义分割只区分“核”和“背景”两类，而实例分割需要区分每一个独立的核个体。在密集的病理解像中，相邻细胞核经常紧密粘连，使得实例分割极具挑战性。

核类型分类 (Nuclear Type Classification)：在完成实例分割的基础上，进一步判断每个核属于哪种细胞类型，例如肿瘤上皮细胞核、炎症细胞核、结缔组织细胞核、死亡细胞核等。不同类型细胞核的空间分布模式对于肿瘤微环境分析至关重要。

第三节 人工分析的局限性与自动化的必要性

目前，细胞核分析主要依赖病理科医生的人工判读。然而，一张典型的全幻灯片图像中包含数以万计的细胞核，人工逐一标注和分析不仅耗时耗力（标注一张 WSI 往往需要数小时），还存在显著的观察者间差异。研究表明，不同病理医生对同一切片的判读结果存在约 15%~30% 的不一致率。因此，开发精确、高效的自动化细胞核分析算法，对于推动数字病理学的临床落地具有重要意义。

第二章 研究现状

第一节 经典方法：基于能量函数的分水岭算法

在深度学习兴起之前，细胞核实例分割主要依赖传统图像处理方法。分水岭算法（Watershed）是最常用的一类方法，通过构造图像的能量景观，将相邻核之间的凹陷区域识别为分界线，从而分离粘连的核实例。然而，这类方法严重依赖手工设计的特征和人工调节的阈值参数，在核形态多样、染色不均匀的真实病理图像上泛化能力有限，且对粘连核的分离效果不稳定。

第二节 深度学习方法的兴起

2.2.1 基于轮廓预测的方法

深度学习方法的早期代表是基于双分支结构的方法。DCAN（2016）提出同时预测核区域和核轮廓的双分支网络，通过从核区域掩码中减去轮廓掩码来分离实例。CIA-Net（2019）在此基础上引入轮廓感知信息聚合模块，进一步提升了轮廓预测精度。这类方法的思路清晰，但轮廓预测在粘连严重的区域往往不准确，且对轮廓宽度的设定敏感。

2.2.2 HoverNet：基于距离图的里程碑方法

HoverNet^[1] 是细胞核实例分割领域最具影响力的方法之一，至今仍是该领域的标准基线。其核心创新是引入“水平-垂直距离图”（Horizontal and Vertical Maps, HoVer Maps）机制：网络预测每个核像素到其所在核质心的水平距离和垂直距离，利用距离图在粘连核边界处的梯度突变来分离相邻核实例。

HoverNet 采用预激活 ResNet50 (Preact-ResNet50) 作为特征提取器，设计了三个并行的解码器分支：核像素分支 (NP Branch) 输出二值分割掩码，HoVer 分支输出距离图，核类型分支 (NC Branch) 输出每个核像素的类型概率。三支联合训练，共享底层特征。

HoverNet 在 CoNSeP、PanNuke、MoNuSAC 等多个数据集上取得了当时最

优的性能，并提供了开源代码和预训练权重，极大地推动了该领域的研究进展。然而，HoverNet 的特征提取器是在 ImageNet（自然图像）上预训练的 ResNet50，与病理图像的视觉域存在较大差异；同时，其基于 patch 的处理方式导致 patch 边界处的核实例容易出现分割误差。

2.2.3 基于 Transformer 的方法

Transformer 在自然语言处理领域的成功很快被迁移到计算机视觉任务。TransNuSeg^[2] 是首个将纯 Transformer 框架（Swin Transformer）应用于细胞核分割的工作，提出了三解码器结构（分别处理核实例、普通边缘和粘连边缘），并引入注意力共享机制减少参数量，以及自蒸馏损失提升多分支一致性，在 MoNuSeg 数据集上相比 CA^{2.5}-Net 提升了 2~3% 的 Dice 分数。CellViT^[3] 则利用 SAM（Segment Anything Model）预训练的 ViT encoder 初始化分割网络，在 PanNuke 数据集上取得了 mPQ=0.50 的成绩。

Transformer 方法的优势在于能够通过自注意力机制捕获全局上下文信息，相比 CNN 具有更强的长程依赖建模能力。然而，标准 Transformer 的计算复杂度与序列长度的平方成正比，对于高分辨率病理图像的处理仍面临计算效率挑战；此外，基于 patch 的处理方式依然没有得到根本解决。

2.2.4 基于 SAM 的适配方法

2023 年，Meta 发布的 Segment Anything Model（SAM）^[4] 在通用图像分割领域引发了广泛关注。SAM 基于超过 10 亿个分割掩码训练，具备强大的零样本泛化能力。多项研究探索了 SAM 在细胞核分割中的应用。

UN-SAM^[5] 提出了无需手动提示的 SAM 框架，设计了多尺度自提示生成模块（SPGen）自动产生分割提示，以及域自适应调优编码器（DT-Encoder）提升跨域泛化能力，在多个数据集上的零样本泛化性能显著优于其他医学 SAM 方法。NuSegDG^[6] 将 SAM 与异质空间适配器（HS-Adapter）和高斯核提示编码器（GKP-Encoder）结合，实现了域泛化的细胞核实例分割，但未涉及核类型分类任务。

这些工作证明了 SAM 强大的特征提取能力在细胞核分割中的价值，但现有方法大多专注于提示机制的设计，尚未充分探索 SAM encoder 与其他序列建模技术的结合。

2.2.5 基于 Mamba 的方法

Mamba^[7] 是一种基于状态空间模型（State Space Model, SSM）的序列建模架构，具有线性时间复杂度，能够在保持全局感受野的同时高效处理长序列。与 Transformer 的二次复杂度相比，Mamba 在处理长序列时具有显著的计算优势。

PanopMamba^[8] 是首个将 Mamba 应用于细胞核分割的工作，提出了多尺度 Mamba 主干与 SSM 融合网络的结合，在 MoNuSAC2020 和 NuInsSeg 数据集上取得了优于现有方法的全景分割性能。Category Prompt Mamba (CPMamba)^[9] 则利用 Mamba 的线性复杂度实现了对完整病理图像（而非 patch）的处理，从根本上解决了 patch 边界对齐问题，在核分割与分类任务上取得了良好效果。

然而，现有 Mamba 方法均未与 SAM encoder 结合，也未在 HoverNet 的成熟三支解解码框架下验证 Mamba 的有效性。

第三节 现有方法的共同局限

综合以上分析，现有方法存在以下几个共同局限：

局限一：特征提取器与病理图像的域偏移问题。大多数方法（包括 HoverNet）使用 ImageNet 预训练的 encoder，而 ImageNet 是自然图像数据集，与 H&E 染色病理图像的视觉特征存在本质差异（色彩分布、纹理模式、目标尺度均不同）。这导致特征提取器对病理图像的适配性不足，限制了分割精度。

局限二：patch 边界处的实例分割误差。由于病理图像分辨率极高，现有方法普遍采用 patch 级处理策略，即将大图切成小块分别处理后再拼接。位于 patch 边界处的细胞核往往被截断，导致这部分核的分割结果出现明显误差，影响整体性能。

局限三：SAM 与序列建模技术的结合尚未探索。SAM 的强边界感知能力

和 Mamba 的高效长程依赖建模各有优势，二者在细胞核实例分割与分类任务中的结合目前尚无相关工作。

第三章 研究问题

基于上述现状分析，本研究聚焦于以下核心问题：

如何设计一个细胞核实例分割与分类框架，使其同时具备：(1) 与病理图像域高度匹配的特征提取能力；(2) 有效建模跨 patch 长程上下文的能力；(3) 在多种组织类型和染色条件下的泛化能力？

具体而言，本研究需要回答以下三个子问题：

(1) SAM 的强边界感知特征是否能够显著提升细胞核实例分割的精度，相比 ImageNet 预训练 encoder 有多大提升？

(2) Mamba 的长程序列建模能否有效缓解 patch 边界处的分割误差，相比无 Mamba 的基线有多大改进？

(3) SAM encoder 与 Mamba 融合模块的结合，是否能在保留 HoverNet 成熟解码器框架的前提下，在多个标准数据集上取得优于现有 SOTA 方法的综合性能？

第四章 研究方案

第一节 总体框架

本研究提出 **SAM-Mamba-HoverNet**，一个融合 SAM 强边界特征、Mamba 长程建模与 HoverNet 成熟解码器的细胞核实例分割与分类框架。整体架构如图 4-1所示。



图 4-1 SAM-Mamba-HoverNet 总体架构图

第二节 各模块设计动机

4.2.1 为什么用 SAM Encoder

SAM (Segment Anything Model) 由 Meta AI 于 2023 年提出，基于超过 1100 万张图像、10 亿个分割掩码训练而成。其核心是一个 ViT-H (Vision Transformer Huge) 图像编码器，具备极强的特征提取能力，尤其对目标边界的感知能力远

超 ImageNet 预训练的 CNN。

与 ResNet50 相比, SAM encoder 在两个关键方面具有优势: 第一, SAM 的预训练任务是分割, 即天然地对边界敏感, 这与细胞核分割对边界精度的要求高度吻合; 第二, SAM 的 ViT-H encoder 通过自注意力机制建模全局特征, 相比 ResNet 的局部感受野具有更强的表达能力。

CellViT (2023) 已经证明, 使用 SAM 预训练权重初始化的 ViT encoder, 在 PanNuke 上的 mPQ 显著优于使用 ImageNet 预训练 encoder 的方法。本研究在此基础上, 进一步引入 Mamba 模块来解决 SAM encoder 自身的局限性。

4.2.2 为什么用 Mamba 融合模块

SAM 的 ViT-H encoder 采用窗口注意力机制 (window attention), 大多数层只在 14×14 的局部窗口内计算注意力, 这意味着单个 token 的感受野仍然受限, 跨窗口 (跨 patch) 的全局上下文信息无法有效传播。

Mamba 基于状态空间模型, 能够以线性时间复杂度处理任意长度的序列, 且每个位置的输出都依赖于完整的历史序列——换言之, Mamba 在建模全局依赖时没有感受野限制。将 SAM encoder 输出的特征图展开为序列后, 通过 Mamba 的 4 方向扫描 (水平前向、水平后向、垂直前向、垂直后向), 可以建模图像中任意两个位置之间的依赖关系, 从而缓解 patch 边界处因缺乏上下文信息导致的分割误差。

具体实现上, 采用 VMamba^[10] 中提出的视觉状态空间块 (VSS Block) 作为基本单元, 在 SAM encoder 的多尺度特征图上分别进行 Mamba 序列建模, 再通过 FPN 式的特征金字塔网络将多尺度特征融合, 输出统一的特征表示。

4.2.3 为什么保留 HoverNet 的解码器

HoverNet 的三支解码器经过数十篇论文的验证, 是目前细胞核实例分割领域最成熟的解码框架之一。其核心机制——hover-map (水平垂直距离图)——在粘连核分离上具有物理意义上的合理性, 且解码器本身轻量 (无需额外标注, GT 可自动从实例掩码计算)。

在本研究中，只替换特征提取的前端（encoder），保留 decoder 不变，这样做有两个优点：一是避免引入过多变量，能够清晰地消融 SAM 和 Mamba 各自的贡献；二是充分利用 HoverNet 在解码器设计上积累的经验，降低实现风险。

第三节 与现有方法的差异对比

表 4-1 与现有主要方法的对比

方法	Encoder	长程建模	分类	主要局限
HoverNet (2019)	ResNet50 (ImageNet)	无	✓	域偏移, patch 边界
TransNuSeg (2023)	Swin-T (ImageNet)	窗口注意力	✓	泛化性不足
CellViT (2023)	ViT-H (SAM)	窗口注意力	✓	patch 级, 无 Mamba
PanopMamba (2026)	Mamba (ImageNet)	✓	×	无 SAM, 仅全景分割
CPMamba (2025)	Mamba	✓	✓	无 SAM encoder
UN-SAM (2024)	ViT-H (SAM)	窗口注意力	×	无 Mamba, 无分类
本研究	ViT-H (SAM)	✓ Mamba	✓	—

本研究是首个将 SAM encoder 与 Mamba 融合模块结合，并在 HoverNet 三支解码框架下应用于细胞核实例分割与分类任务的工作。

第五章 实验设计

第一节 数据集

本研究使用以下五个公开数据集进行训练和评估：

PanNuke（主实验数据集）^[11]：由 Warwick 大学发布，包含来自 19 种组织类型的 7901 张 256×256 病理图像 patch，标注了 5 类细胞核（肿瘤上皮、炎症、结缔组织、死亡、普通上皮）。PanNuke 是目前细胞核分割与分类任务最常用的基准数据集之一，具有组织类型多样、类别标注完整的特点。

MoNuSeg^[12]：多器官细胞核分割数据集，包含来自 7 种器官的 44 张训练图像和 14 张测试图像，仅包含实例分割标注（无类型标注）。用于评估模型在不同器官 H&E 切片上的泛化能力。

CoNIC (Lizard 数据集)：结肠细胞核识别与计数数据集，包含约 4981 张 patch，标注 6 类细胞核，来自 6 种结肠组织。

MoNuSAC：多器官多类型细胞核分割挑战赛数据集，包含来自 4 种器官的标注，共 4 类细胞核。

CoNSeP：结直肠腺癌数据集，包含 41 张 1000×1000 的 H&E 图像，标注 4 类细胞核，由 HoverNet 原作者发布。

第二节 评估指标

AJI (Aggregated Jaccard Index)：聚合 Jaccard 指数，综合衡量实例分割的检测和分割质量，是 MoNuSeg 上最常用的评估指标。

PQ (Panoptic Quality)：全景质量，分解为检测质量 (DQ) 和分割质量 (SQ) 两部分，能够分别反映检测精度和掩码精度，是目前最全面的实例分割评估指标。

mPQ (mean Panoptic Quality)：多类别平均全景质量，在 PanNuke 等含类型标注的数据集上使用，反映分类精度与分割精度的综合表现。

F1 (Detection F1): 检测层面的 F1 分数，反映模型发现细胞核的能力。

第三节 对比方法

本研究与以下方法进行公平对比（使用相同训练集、相同数据增强、相同评估协议）：

- HoverNet (ResNet50, 2019) ——经典 baseline
- TransNuSeg (Swin-T, 2023)
- CellViT (ViT-H SAM, 2023)
- UN-SAM (ViT-H SAM, 2024)
- PanopMamba (Mamba, 2026)
- CPMamba (Mamba + Category Prompt, 2025)

第四节 消融实验

为了验证各个模块的贡献，设计以下消融实验，如表 5-1所示。

表 5-1 消融实验设计

消融组	Encoder	Mamba 融合	预期结论
A (baseline)	ResNet50	×	HoverNet 原始性能
B	VMamba (ImageNet)	×	仅换 Mamba encoder 的效果
C	SAM ViT-H	×	仅 SAM encoder 的效果
D (完整模型)	SAM ViT-H	✓	SAM+Mamba 联合效果
E	SAM ViT-H (全冻结)	✓	微调策略的影响
F	SAM ViT-H (全微调)	✓	微调策略的影响
G	SAM ViT-H	✓ (仅深层)	Mamba 融合位置的影响

参考文献

- [1] GRAHAM S, VU Q D, RAZA S E A, et al. HoVer-Net: Simultaneous segmentation and classification of nuclei in multi-tissue histology images[J/OL]. Medical Image Analysis, 2019, 58: 101563. DOI: [10.1016/j.media.2019.101563](https://doi.org/10.1016/j.media.2019.101563).
- [2] HE Z, UNBERATH M, KE J, et al. TransNuSeg: A lightweight multi-task transformer for nuclei segmentation[A]. 2023.
- [3] HÖRST F, REMPE M, HEINE L, et al. CellViT: Vision transformers for precise cell segmentation and classification[A]. 2023.
- [4] KIRILLOV A, MINTUN E, RAVI N, et al. Segment anything[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2023: 4015-4026.
- [5] CHEN Z, XU Q, LIU X, et al. UN-SAM: Universal prompt-free segmentation for generalized nuclei images[J/OL]. IEEE Transactions on Medical Imaging, 2024. DOI: [10.1109/TMI.2024.3414941](https://doi.org/10.1109/TMI.2024.3414941).
- [6] LOU Z, XU Q, JIANG Z, et al. NuSegDG: Integration of heterogeneous space and gaussian kernel for domain-generalized nuclei segmentation[A]. 2024.
- [7] GU A, DAO T. Mamba: Linear-time sequence modeling with selective state spaces [A]. 2023.
- [8] ANONYMOUS. Vision state space modeling for nuclei panoptic segmentation[A]. 2026.
- [9] ZHAO J, et al. Category prompt mamba network for nuclei segmentation and classification[A]. 2025.
- [10] LIU Y, TIAN Y, ZHAO Y, et al. VMamba: Visual state space model[A]. 2024.
- [11] GAMPER J, KOOHBANANI N A, BENET K, et al. PanNuke dataset extension, insights and baselines[A]. 2020.
- [12] KUMAR N, VERMA R, ANAND D, et al. A multi-organ nucleus segmentation challenge[J/OL]. IEEE Transactions on Medical Imaging, 2020, 39(5): 1380-1391. DOI: [10.1109/TMI.2019.2947628](https://doi.org/10.1109/TMI.2019.2947628).